Univerzitet u Sarajevu
Elektrotehnički fakultet
Odsjek za računarstvo i informatiku

Projekat I

Dio I : **Analiza i čišćenje dataseta**

- Mašinsko učenje -

Studenti:

Benjamin Hadžihasanović (2427/19319)
Tarik Čaluk (2390/19351)
Elma Tirak 2336/19282

Sarajevo, decembar 2025.

Zadatak 1.1

Tema: Predikcija napuštanja korisnika u bankarskom sektoru
Tip problema: binarna klasifikacija
Naziv dataset-a: BunkChunkers.csv
Link:https://www.kaggle.com/datasets/thedevastator/predicting-credit-card-customer-attrition-with-m
Ciljna varijabla: Attrition_Flag (ima dvije moguće vrijednosti: Existing Customer, Attrited Customer)

Zadatak 1.2

U okviru zadatka je bilo potrebno izvršiti različite promjene nad dodijeljenim datasetom i svaka od tih promjena je naznačena u Google Colab-u. Okvirno je nad svakom kolonom izvršeno 10%-25% različitih promjena. Promjene su po kolonama navedene u nastavku:

1) Gender 10%
- 5% Female u female
- 5% Male u male

2) SeniorCitizen
- 6% 0 u nula
- 7% 1 u jedan

3) Partner
- 4% No u Noo
- 4% Yes u Yess
- 3% No u Yes

4) Dependents
- 6% No u "No "
- 3% Yes u No

5) tenure
- 3% instanci dobija šum od +-3%
- 4% vrijednosti koje imaju vrijednost = 12 stavljeno je kao 1

6) Phone Service
- 7% podataka No u NO
- 10% Yes u YES
- 4% Yes u 1

7) MultipleLines
- 8% No u no
- 4% Yes u No phone service
- 4% No Phone service u No fon servis
- 5% podataka Yes u YEEES

8) InternetService
- 10% DSL u DLS
- 5% Fiber optic u Fibre optic

9) OnlineSecurity
- 5% No internet service ----> No Intemet service
- 2% No u Yes
- 3% No u NE
- 3% Yes u DA

10) OnlineBackup
- 5% No internet service u No service
- 8% Yes u YesYes
- 5% No u NOU

11) DeviceProtection
- 7% No internet service u NEMA INTERNETA
- 8% No u NE
- 3% Yes u null

12) TechSupport

- 5% No internet service u No net
- 5% Yes u No
- 8% No u *No*

13) StreamingTV

- 4% Yes u null
- 6% No u 0
- 5% No internet service u No service internet

14) StreamingMovies

- 6% Yes u 1
- 5% No u No_No_No
- 8% No internet service u NO INTERNET SERVICE

15) Contract

- 10% Month-to-month u M2M
- 5% One year u 1 year
- 3% Two year u Three year
- 4% Two year u TWO YEAR

16) PaperlessBilling

- 7% No u No_NO_no
- 5% Yes u DA
- 5% No u N0

17) PaymentMethod

- 8% Electronic check u E-check
- 5% Credit card (automatic) u credit-card-auto
- 5% Mailed check u Mail check
- 8% Bank transfer (automatic) u Bank tranfser (automatic)

18) MonthlyCharges

- 5% MonthlyCharges u ceil

  7% redova u pretvoreno u string

  8% redova ubačeno @ na početku

19) TotalCharges

- 8% vrijednosti dodato na početku i na kraju *!*
- od 5% vrijednosti je oduzet broj 5
- 3% vrijednosti obrisana . kod decimalnog broja
- Kod 3% vrijednosti je dodata 0 na početku

20) Churn- ciljna varijabla (bez promjena)

Zadatak 1.3

Prije provođenja detaljne analize varijabli, inicijalno nike bilo moguće izvršiti validnu statističku obradu podataka. Razlog je taj da su sve numeričke varijable iz izvornog skupa podataka izmijenjene u string tip podataka usljed prisustva različitih promjena i nevalidnih znakova. S obzirom na to da se nad tekstualnim podacima ne mogu primijeniti statističke metode kao što su srednaj vrijednost, standardna devijavija, distribucije i korelacije, prvo smo očistili dataset i transformisali podatke tako da budu interpretabilni i iskoristivi za ovaj vid analize.

U prvom koraku izvršeno je učitavanje i osnovni pregled prljavog skupa podataka. Dataset sadrži 10 127 instanci i 25 atributa. Pri ovom koraku primijećeno je da su sve varijable tipa object, što ukazuje na to da svaka kolona sadrži određene izmjene.

Tipovi podataka po kolonama:

	0
CLIENTNUM	object
Attrition_Flag	object
Customer_Age	object
Gender	object
Dependent_count	object
Education_Level	object
Marital_Status	object
Income_Category	object
Card_Category	object
Months_on_book	object
Total_Relationship_Count	object
Months_Inactive_12_mon	object
Contacts_Count_12_mon	object
Credit_Limit	object
Total_Revolving_Bal	object
Avg_Open_To_Buy	object
Total_Amt_Chng_Q4_Q1	object
Total_Trans_Amt	object
Total_Trans_Ct	object
Total_Ct_Chng_Q4_Q1	object
Avg_Utilization_Ratio	object
Naive_Bayes_Classifier_Attrition_Flag_Card_Category_Contacts_Count_12_mon_Dependent_count_Education_Level_Months_Inactive_12_mon_1	object
Naive_Bayes_Classifier_Attrition_Flag_Card_Category_Contacts_Count_12_mon_Dependent_count_Education_Level_Months_Inactive_12_mon_2	object
Account_Status	object
Last_Login_Days	int64

dtype: object

Slika 1: Prikaz tipa svake varijable

Obzirom da je posljednja kolona tipa int, uradićemo analizu za ovu kolonu.

```
df['Last_Login_Days'].describe()
```

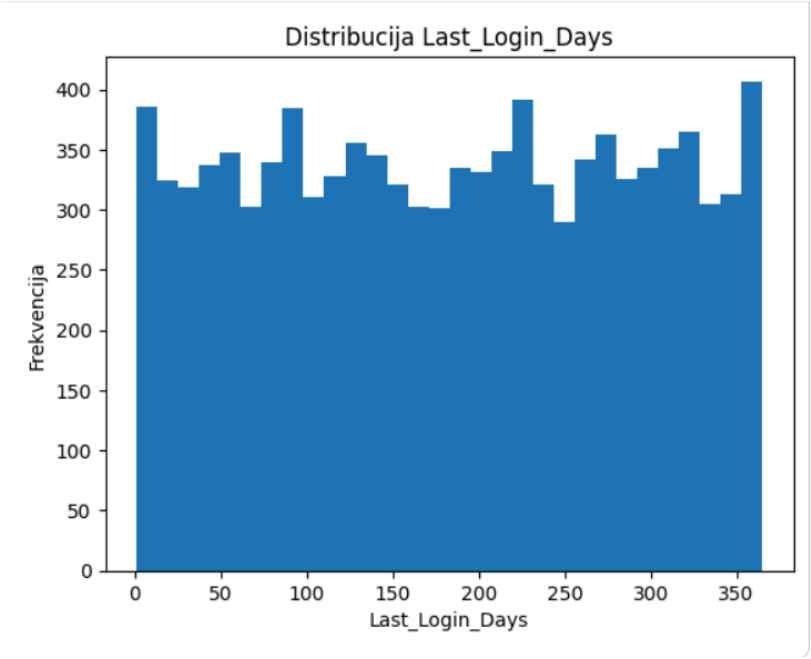
	Last_Login_Days
count	10127.000000
mean	183.607781
std	106.048092
min	1.000000
25%	92.000000
50%	185.000000
75%	276.000000
max	365.000000

dtype: float64

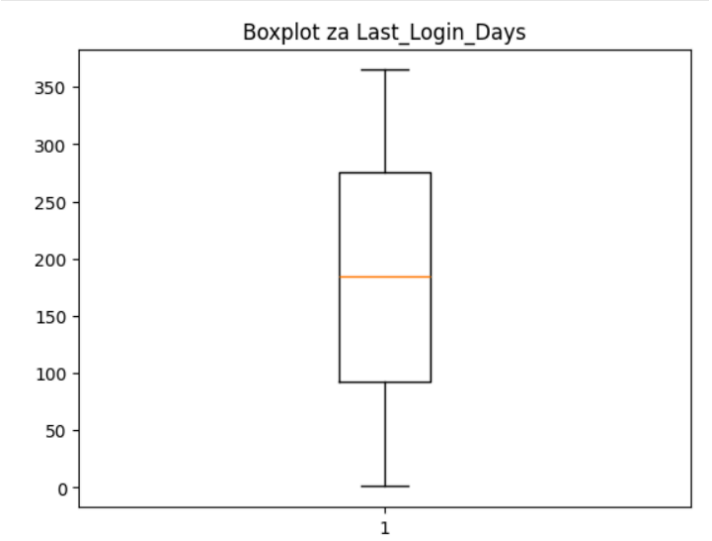
Slika 2: Deskriptivna analiza za kolonu Last_Login_Days

Prema ovoj analizi *(slika 2)* za kolonu Last_Login_Days koja još uvijek nike očišćena imamo ukupno 10 127 zapisa, prosječan broj dana je oko 184, a standardna devijacija pokazuje značajnu varijabilnost.

Što se tiče same distribucije ona je prikazana na *slici 3*. Ovo je prikaz uniformne distribucije. Svi stubovi između vrijednosti 300 i 400 su gotovo iste visine, što bi značilo da postoji jednaka vjerovatnoća da se klijent ulogovao prije 1 dan, prije 150 dana ili prije 365 dana, što u realnom svijetu gotovo nikada niej slučaj.



Slika 3: Distribucija Last_Login_Days



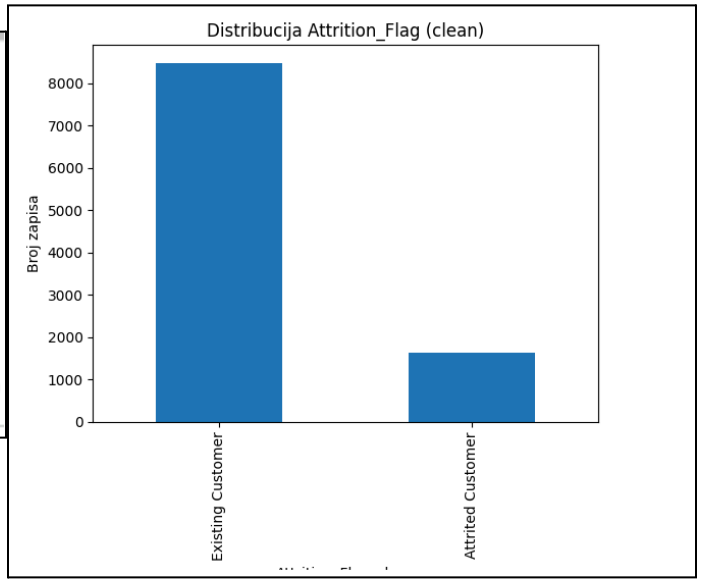
Slika 4: Boxplot za Last_Login_Days

Na *slici 4* prikazan je boxplot kojim se dodatno potvrđuje vještačka priroda podataka za kolonu Last_Login_Days. Dijagram prikazuje savršeno simetričnu distribuciju s medijanom pozicioniranom tačno na sredini raspona i kvartilima koji se dijele na jednake dijelove. Potpuno odsustvo outliera ukazuju na to da podaci nisu rezultat stvarnog ponašanja korisnika, već vjerovatno produkt uniformnog generatora slučajnih brojeva.

Zadatak 1.4

Kolona **Attrition_Flag** predstavlja ciljnu varijablu binarne klasifikacije. Analizom vrijednosti je utvrđeno postojanje velikog broja nevalidnih zapisa koji ne pripadaju nijednoj od dvije očekivane klase. U prvom koraku su podaci noramlizovani za identifikaciju ključnih riječi unutar stringova; iskorištena je metoda fuzzy matching za ispravljanje grešaka nastalih usljed permutacije ili pogrešnog unosa znakova. Na ovaj način su sve vrijednosti mapirane na 2 validne kategorije: Existing Customer i Attrited Customer.

```
(Attrition_Flag_clean
 Existing Customer    8483
 Attrited Customer    1644
 Name: count, dtype: int64,
 Attrition_Flag_clean
 Existing Customer    83.76617
 Attrited Customer    16.23383
 Name: proportion, dtype: float64)
```



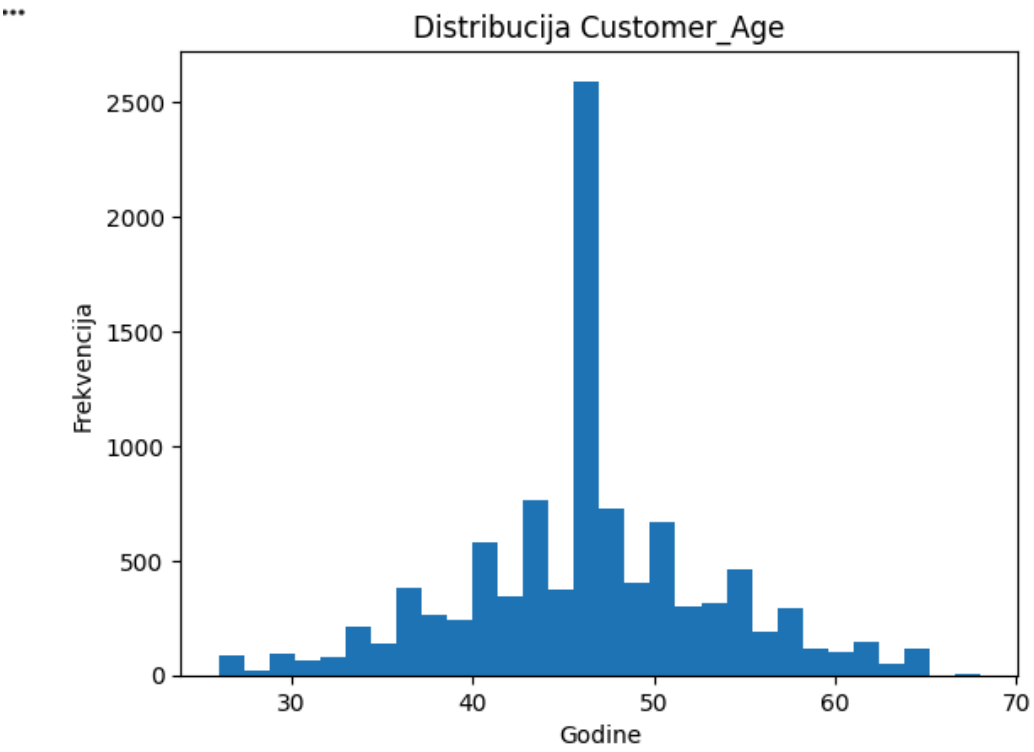
Slika 5: Analiza ciljne varijable

Na *slici 5* se može vidjeti da ulogu postojećih korisnika ima 8 483 korisnika, a da je broj korisnika koji su napustili uslugu je 1 644. Ovo pokazuje izraženu neuravnoteženost klasa, u procentima je to 83.77% da pripada i 16.23% da ne pripada.

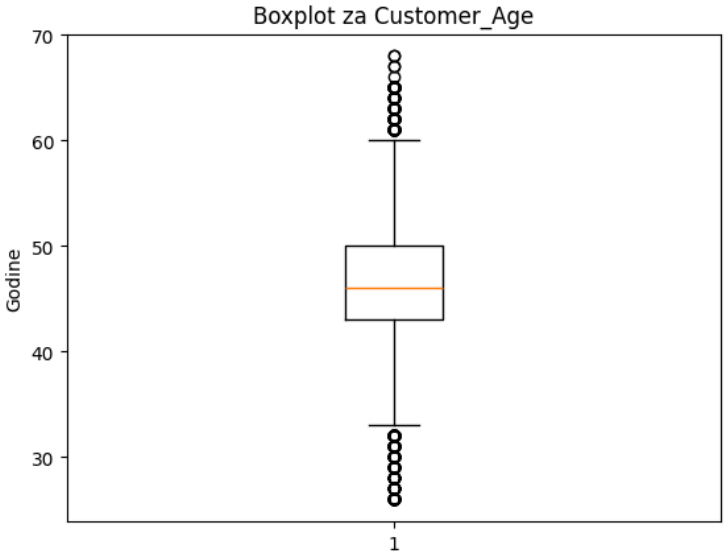
Za kolonu **Customer_Age** su uočene nevalidne vrijednosti u vidu tekstualnih simbola, negativnih i ekstremno velikih brojeva koje ne odgovaraju realnom opsegu starosti klijenata. Nakon uklanjanja nebrojčanih znakova i konverzije podataka u numerički tip, vrijednosti koje su bile izvan realnog domena starosti (manje od 18 i veće od 100) tretirane su kao nepodobne i označene kao nedostajuće. Potom su ove vrijednosti zamijenjene korištenjem medijane te kolone, čime je očuvana distribucija podataka.

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean        46.253678
std          7.050153
min         26.000000
25%         43.000000
50%         46.000000
75%         50.000000
max         68.000000
Name: Customer_Age_clean, dtype: float64
```

Slika 6: Deskriptivna statistika za Customer_Age



Slika 7: Distribucija za Customer_Age



Slika 8: Boxplot za Customer_Age

Histogram *(slika 7)* prikazuje raspodjelu starosti korisnika u skupu podataka. Uočava se da se najveći broj korisnikka nalazi u rasponu između 40 i 50 godina, što ukazuje da su srednje starosne grupe dominantne. Distribucija je približno simetrična, sa blagim odstupanjima na krajevima ovog raspona. Ovakav oblik distribucije nam ukazuje na stabilnu i realnu raspodjelu vrijednosti nakon procesa čišćenja podataka.

Boxplot *(slika 8)* prikazuje centralnu tendenciju ove varijable. Medijana se nalazi oko srednjih četrdesetih godina, dok interkvartilni raspon obuhvata vrijednosti između 43 i 50 godina, što ukazuje na umjerenu varijabilnost starosti korisnika. Prisustvo manjeg broja outliera na donjoj i gornjoj granici raspona ukazuje na korisnike koji pripadaju mlađim i starijim starosnim grupama, ali se te vrijednosti nalaze u realnim granicama. Ekstremne vrijednosti ne postoje.

Kod kolone **Gender** je utvrđeno postojanje dodatnih zapisa za muški i ženski pol, koji su sadržavali dodatne tekstualne oznake. Izvršena je standardizacija zapisa mapiranjem svih varijanti koje počinju sa F na vrijednost F, odnosno svih varijanti koje započinju sa M na vrijednost M. Zapisi kod kojih vrijednost pola nije bila dostupna ili se nije mogla odrediti su izmijenjene modusom (najfrekventnijom kategorijom).

```
Prije čišćenja: ['M' 'F' 'M_ERROR_VALUE' 'M_UNKNOWN' nan 'F_ERROR_VALUE' 'F_UNKNOWN'
 'M_RANDOM_TEXT' 'F_NOT_VALID' 'M_NOT_VALID' 'F_RANDOM_TEXT']
Poslije čišćenja: ['M' 'F']
Gender_clean
F    5502
M    4625
Name: count, dtype: int64
```

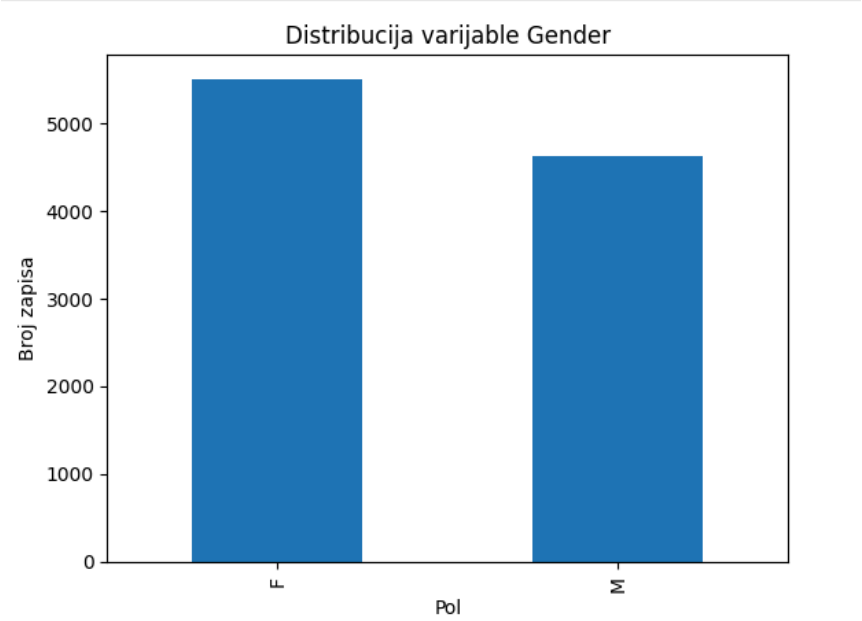
```
df['Gender_clean'].value_counts()
```

Gender_clean	count
F	5502
M	4625

dtype: int64

Slika 9: Distribucija varijable Gender

Slika 9 pokazuje stanje prije i poslije čišćenja, kao i konačnu distribuciju vrijednosti u koloni Gender_clean. Prije čišćenja, varijabla je imala veliki broj nekonzistentnih i nepravilnih vrijednosti, a nakon primjene čišćenja sve vrijednosti su mapirane u 2 kategorije: F i M. Konačna distribucija pokazuje da je u skupu podataka zastupljeno 5502 korisnika ženskog pola (F) i 4625 korisnika muškog pola (M).



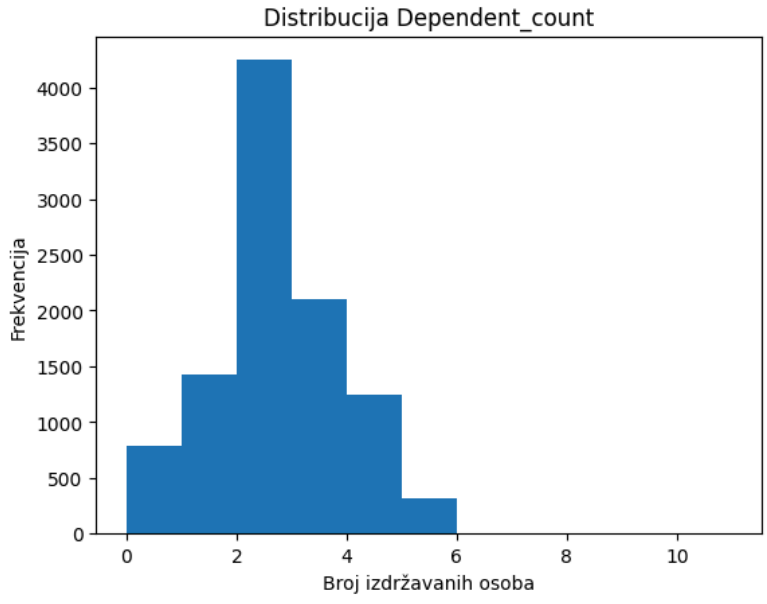
Slika 10: Histogram distribucije varijable Gender

Kolona **Dependent_count** sadržavala je značajnu količin šuma u podacima, negativnih vrijednosti, dodatnih simobla, kao i nedostajućih vrijednosti. Prvo su uklonjeni svi nebrojčani znakovi iz kolone, nakon čega su vrijednosti konvertovane u numerički tip podataka. Sve negativne vrijednosti i vrijednosti veće od 10 su označene kao nevalidne. Nedostajuće vrijednosti su izmijenjene korištenjem medijane za tu kolonu čime je očuvana distribucija podataka.

```
• Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean         2.252395
std          1.171324
min          0.000000
25%          2.000000
50%          2.000000
75%          3.000000
max          5.000000
Name: Dependent_count_clean, dtype: float64
Dependent_count_clean
0.0     787
1.0    1424
2.0    4248
3.0    2102
4.0    1246
5.0     320
Name: count, dtype: int64
```

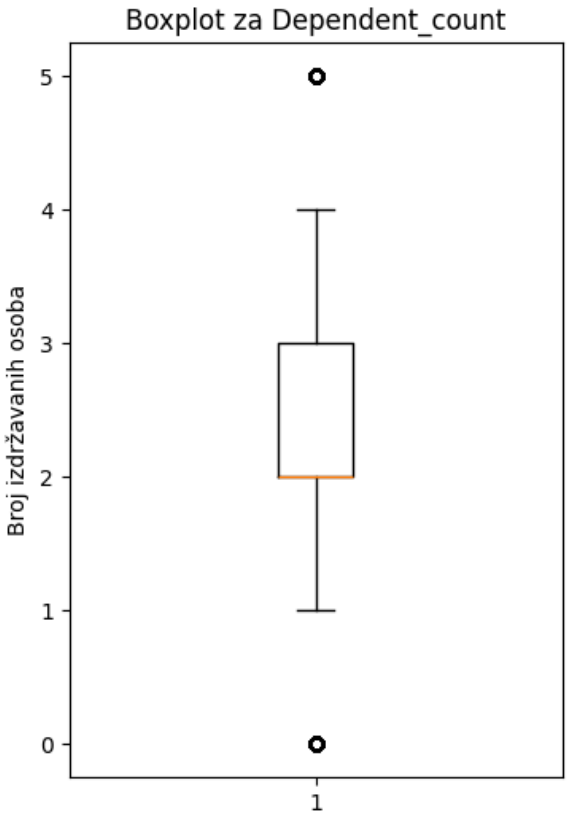
Slika 11: Deskriptivna statistika za kolonu Dependent_count

Nakon čišćenja su svi redovi sačuvani, dakle svih 10127 vrijednosti, srednja vrijednost iznosi oko 2, što znači da prosječan korisnik ima oko 2 izdržavane osobe. Medijan iznosi 2, pa između srednje vrijednosti i medijana nema jake asimetrije. Većina korisnika se ne razlikuje mnogo od prosjeka. *(slika 11)*



Slika 12: Histogram distribucije Dependen_count

Histogram *(slika 12)* prikazuje raspodjelu broja izdržavanih osoba po korisniku. Distribucija je desno asimetrična. Vrijednosti iznad 4 su rijetke i predstavljaju manji dio populacije, ali se i dalje nalaze u relanim i očekivanim demografskim granicama.



Slika 13: Boxplot za Dependent_count

B*o*xplot *(slika 13)* prikazuje centralnu tendenciju i raspianje broja izdržavanih osoba po korisniku. Medijana se nalazi na vrijednosti 2, a interkvartilni raspon obuhvata približno između vrijednosti 2 i 3 što ukazuje na relativno malu varijabilnost unutar srednjih 50% podataka. Vrijednosti 0 i 5 se pojavljuju kao rijetki slučajevi i označene su kao potencijalni outlier, ali se i dalje nalze u realnim granicama i ne predstavljaju greške u podacima.

Kolona **Education_Level** je, pored stalnih nivoa obrazovanja, uključivala i 768 jedinstvenih vrijednosti nasumičnih tekstualnih vrijednosti koje nisu predstavljale validne nivoe obrazovanja.

Za čišćenje ove kolone korištena je metoda pretrage podstringova za identifikaciju validnih kategorija unutar neispravnih zapisa. Za preostale zapise je primijenjen fuzzy matching, metoda aproksimativnog sparivanja stringova, koja je na osnovu leksičke sličnoti mapirala neispravne unose u jedno od 7 standardnih kategorija.

```
Broj kategorija prije: 767
Broj kategorija poslije: 7

Rezultat:
Education_Level_clean
Graduate         3041
Unknown          1915
High School      1892
Uneducated       1384
College           980
Post-Graduate     476
Doctorate         439
Name: count, dtype: int64
```

Slika 14: Distribucija za kolonu Education_Level

Na *slici 14* se može vidjeti da su sve vrijednosti iz datasets sa neispravnim podacima mapirane na validne nivoe obrazovanja tak oda je kolona sada standardizovana. Prema ovoj distribuciji najveći broj korisnika ima završen fakultet, ali je značajan broj zapisa i u kategoriji Unknown, što ukazuje na nedostatak informacija o obrazovanju. Najviši nivoi obrazovanja su najmanje zastupljeni i distribucija je neuravnotežena.

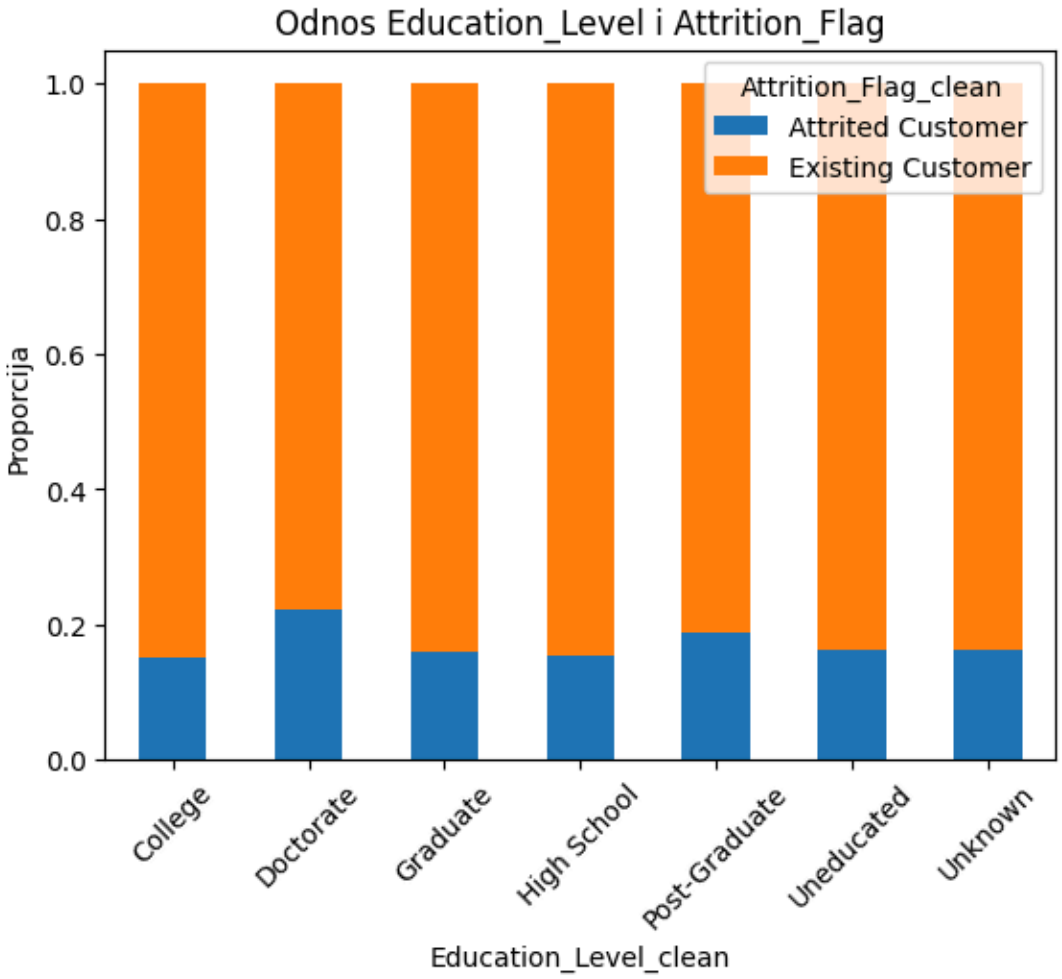
```
pd.crosstab(
    df['Education_Level_clean'],
    df['Attrition_Flag_clean'],
    normalize='index'
)
```

Education_Level_clean	Attrited Customer	Existing Customer
College	0.152041	0.847959
Doctorate	0.220957	0.779043
Graduate	0.158500	0.841500
High School	0.153805	0.846195
Post-Graduate	0.186975	0.813025
Uneducated	0.161127	0.838873
Unknown	0.163446	0.836554

Slika 15: Kontigencijska tabela normalizovana po redovima

Na *slici 15* je prikazana kontigencijska tabela koja pokazuje proporciju korisnika koji su napustili uslugu i onih koji su ostali unutar svake obrazovne kategorije. Rezultati ukazuju da se stopa napuštanja usluge razlikuje u zavisnosti od nivoa obrazovanja. Najvišu proporciju korisnika koji su napustili uslugu ima kategorija Doctorate (oko 22%), dok su najniže stope zabilježene kod korisnika sa završenim fakultetom (*Graduate*) i srednjim obrazovanjem (*High School*), gdje stopa napuštanja iznosi približno 15–16%. Kategorije *College*, *Uneducated* i *Unknown* pokazuju slične vrijednosti, sa stopom napuštanja oko 16%.

Ovi rezultati ukazuju da nivo obrazovanja može imati određeni uticaj na vjerovatnoću napuštanja usluge, iako razlike između većine kategorija nisu izrazito velike. Varijabla *Education_Level_clean* stoga može imati umjeren prediktivni značaj u kombinaciji sa drugim demografskim i ponašajnim varijablama.



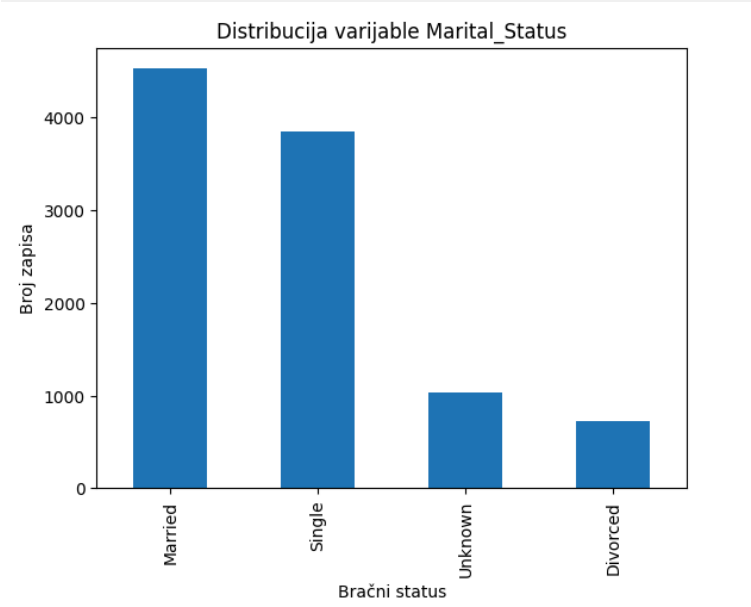
Slika 16: Dijagram koji prikazuje odnos između varijabli Education_Level i Attrition_Flag

Kod kolone **Marital_Status** uočen je veliki broj nekonzistentnih zapisa za iste bračne statuse, uključujući tipografske greške, dodatne tekstualne oznake i nasumične tekstualne vrijednosti. Međutim, svi zapisi mogu da se svrstaju u odgovarajuće kategorije na osnovu pretrage podstringova i algoritma za mjerenje sličnosti teksta (fuzzy matching). Na ovaj način su svi zapisi mapirani na validne kategorije Married, Single, Divorced ili Unknown.

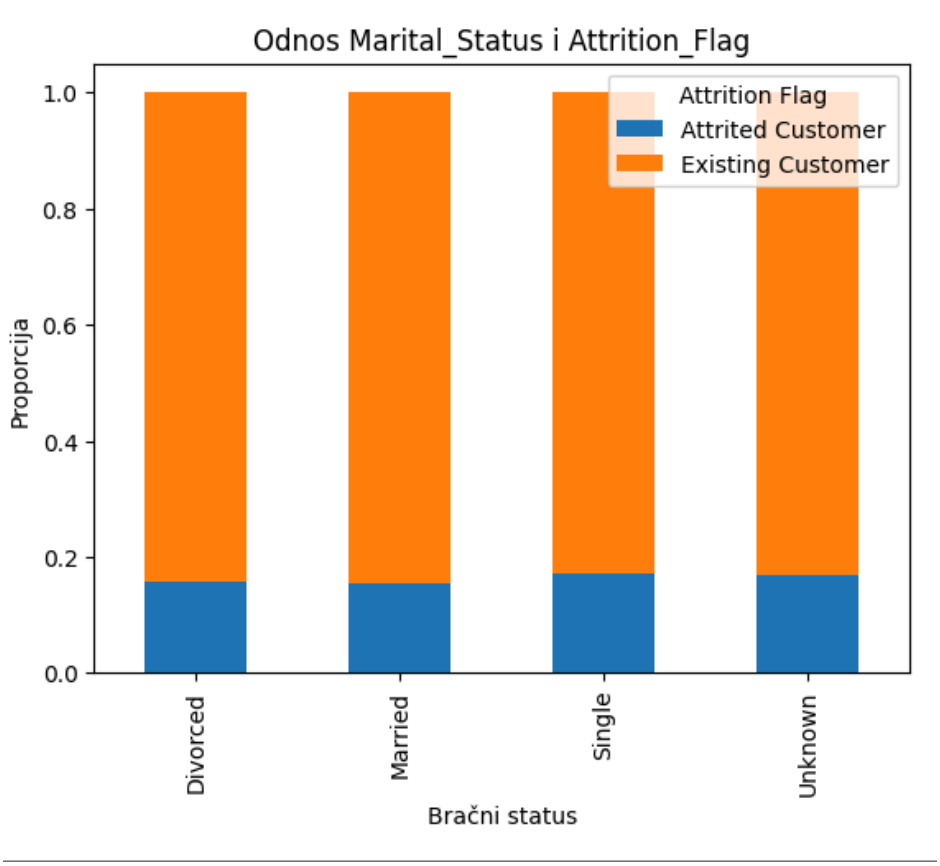
```
Broj kategorija prije: 212
Broj kategorija poslije: 4
Marital_Status_clean
Married     4522
Single      3847
Unknown     1036
Divorced     722
Name: count, dtype: int64
```

Slika 17: Distribucija za varijablu Marital_Status

Slika 17 prikazuje stanje varijable Marital_Status prije i poslije procesa čišćenja, kao i konačnu raspodjelu vrijednosti. Prije čišćenja, varijabla je sadržavala veliki broj nekonzistentnih zapisa, ukupno 212 različitih kategorija. Nakon primjene metoda normalizacije i fuzzy matchinga, varijabla je svedena na četiri validne kategorije: Married, Single, Divorced i Unknown. Distribucija pokazuje da najveći broj korisnika pripada kategoriji Married, dok su kategorije Single i Divorced zastupljene u manjem broju. Prisutnost kategorije Unknown ukazuje na dio zapisa bez pouzdane informacije o bračnom statusu.



Slika 18: Bar dijagram raspodjele korisnika prema bračnom statusu



Slika 19: Odnos varijable Attrited Customer i Existing Customer

Na *slici 19* može se uočiti da proporcija korisnika koji su napustili uslugu varira između bračnih statusa. Kategorije Single i Unknown pokazuju nešto veći udio korisnika koji su napustili uslugu u poređenju sa kategorijama *Married* i *Divorced*, kod kojih je stopa napuštanja blago niža.

Ovi rezultati ukazuju da bračni status može imati umjeren uticaj na vjerovatnoću napuštanja usluge, ali razlike između kategorija nisu izrazito velike, što sugeriše da varijabla sama po sebi nema dominantan prediktivni značaj, već može doprinijeti modelu u kombinaciji sa drugim varijablama.

Kolona **Income_Category** je sadržavala veliki broj nekonzistentnih zapisa, uključujući različite valute, pogrešne formate i nasumičan tekstualni šum. Svaki zapis je prvo transformisan u string i preveden u mala slova, čime su uklonjene razlike nastale usljed velikih/malih slova i različitih tekstualnih formata. Zapisi koji nisu sadržavali nikakve numeričke informacije klasifikovani su u kategoriju *Unknown*, jer nije bilo moguće pouzdano odrediti prihodnu grupu. Preostale vrijednosti su klasifikovane primjenom hijerarhijskog skupa pravila, pri čemu je redoslijed provjere bio ključan za izbjegavanje preklapanja između kategorija. Prisustvo cifara 8, 1 i 2 u zapisu korišteno je za identifikaciju kategorije *$80K–$120K*, dok kombinacija cifara 6 i 8 označava raspon *$60K–$80K*. Zapisi koji sadrže cifre 4 i 6 mapirani su u kategoriju *$40K–$60K*. U slučajevima gdje zapis sadrži cifre 1 i 2 bez prisustva cifre 8, vrijednost je klasifikovana kao *$120K+*, dok je prisustvo cifre 4 bez cifre 6 korišteno za označavanje kategorije *Less than $40K*.

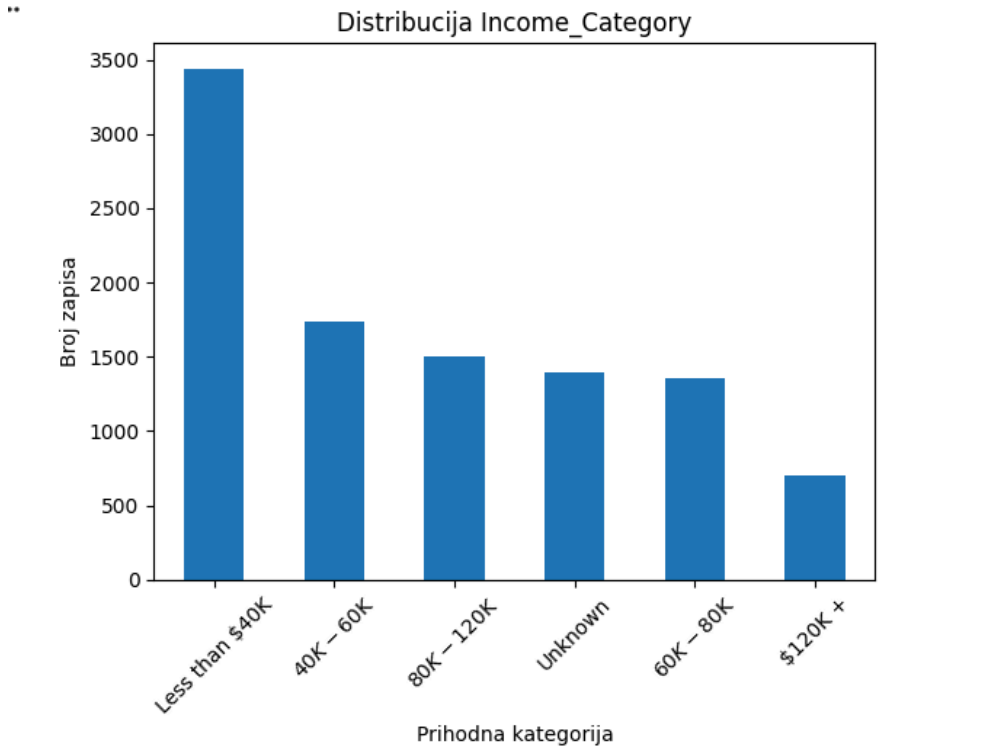
Svi zapisi koji nisu zadovoljili nijedan od definisanih uslova svrstani su u kategoriju *Unknown*, čime je osigurana konzistentnost podataka i izbjegnuto uvođenje potencijalno pogrešnih vrijednosti.

```
Broj kategorija prije: 930
Broj kategorija poslije: 6

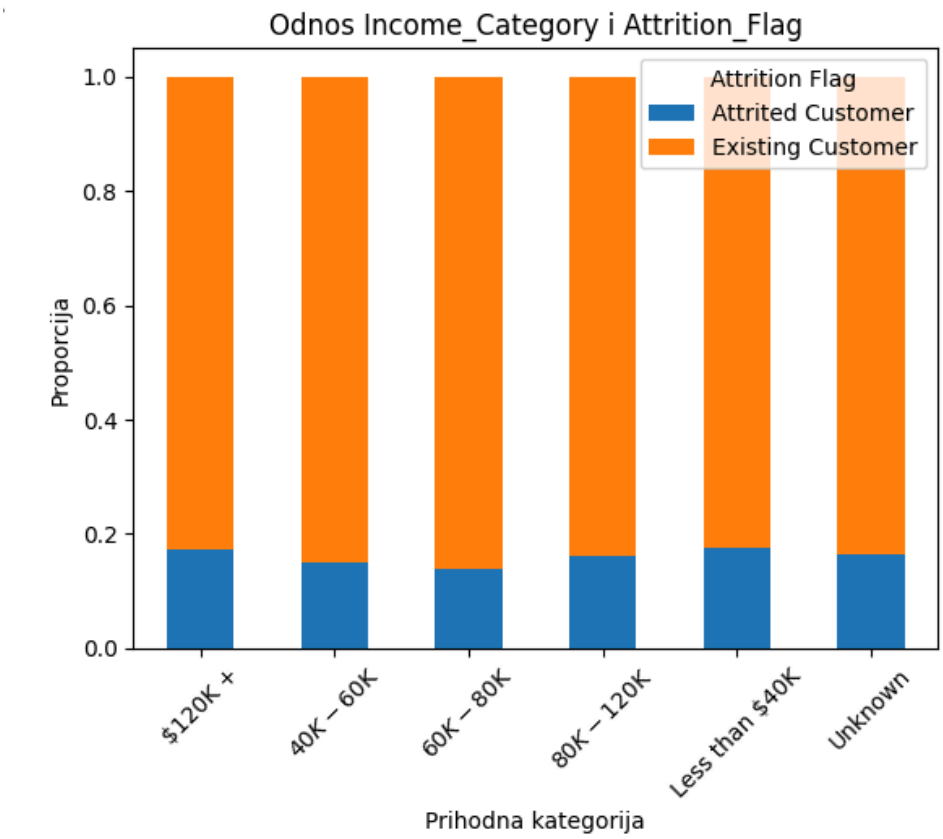
Rezultat:
Income_Category_clean
Less than $40K    3438
$40K - $60K       1737
$80K - $120K      1499
Unknown           1391
$60K - $80K       1357
$120K +            705
Name: count, dtype: int64
```

Slika 20: Prikaz distribucije za kolonu Income_Category

Slika 20 prikazuje stanje varijable Income_Category prije i poslije procesa čišćenja, kao i konačnu raspodjelu korisnika po kategorijama. Prije čišćenja, varijabla je sadržala 930 različitih kategorija, a nakon čišćenja se može primijetiti da sadrži 6 jasno definisanih kategorija. Konačna distribucija pokazuje da najveći broj korisnika pripada kategoriji Less than $40K, dok su kategorije$40 K-$60K, $60K–$80K i $80K–$120K umjereno zastupljene. Kategorija $120K+ je najmanje zastupljena, što je očekivano s obzirom na prirodu raspodjele prihoda u populaciji. Značajan broj zapisa klasifikovan je kao Unknown, što ukazuje na prisustvo nedostajućih ili nepouzdanih informacija o prihodima kod dijela korisnika.



Slika 21: Prikaz raspodjele korisnika u određene kategorije



Slika 22: Odnos varijabli Income_Category i Attrition_Flag

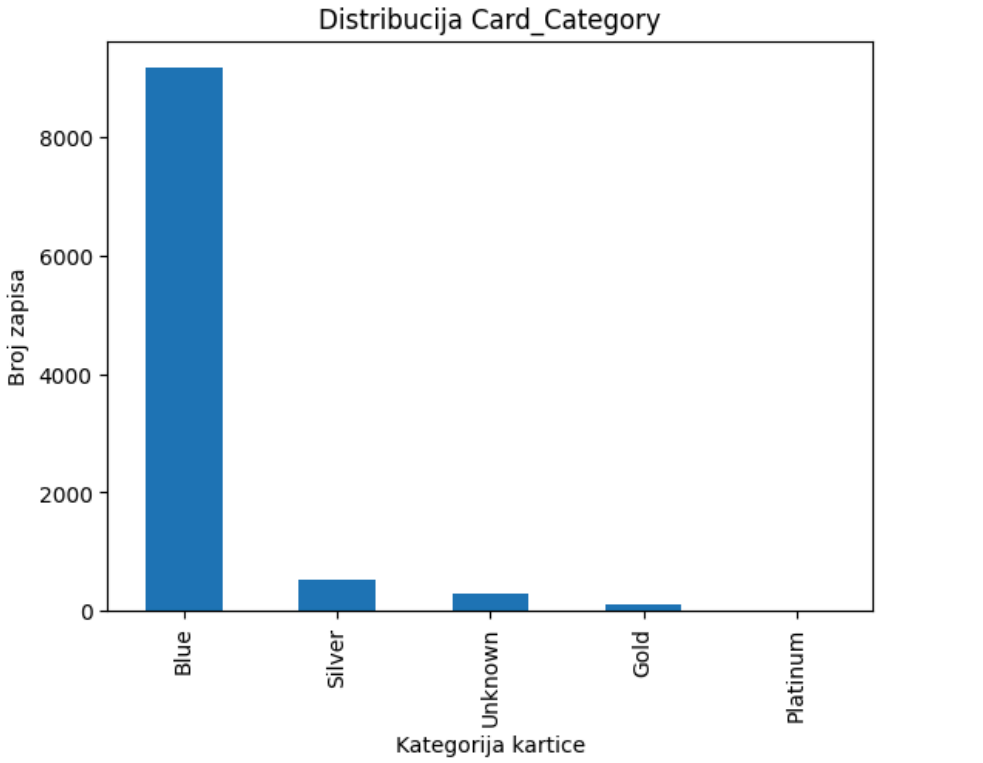
Analizom odnosa između kategorije prihoda i statusa klijenta, uočava se da je stopa odlazaka (churn rate) relativno uniformna kroz sve kategorije. Udio klijenata koji napuštaju banku (prikazan plavom bojom) kreće se u približno istom rasponu (oko 15-20%) bez obzira na to da li klijent zarađuje manje od 40k ili više od 120k dolara.

U koloni **Card_Category** bilo je dosta neispravnih zapisa, dodatnih tekstualnih oznaka. Prvi pristup čišćenju ove kolone bilo je mapiranje zasnovano na prepoznavanju karakterističnih dijelova riječi, čime su objedinjeni zapisi sa dodatnim sufiksima. U drugok koraku je korištena metoda zasnovana na sličnosti stringova radi ispravljanja zapisa koji nisu obuhvaćeni u prvom koraku . Zapisi koji nisu mogli validno da se mapiraju su svrstani u kategoriju Unknown. Nakon izvršenih transformacija kolona sadrži isključivo kategorije: Blue, Silver, Gold, Platinum i Unknown.

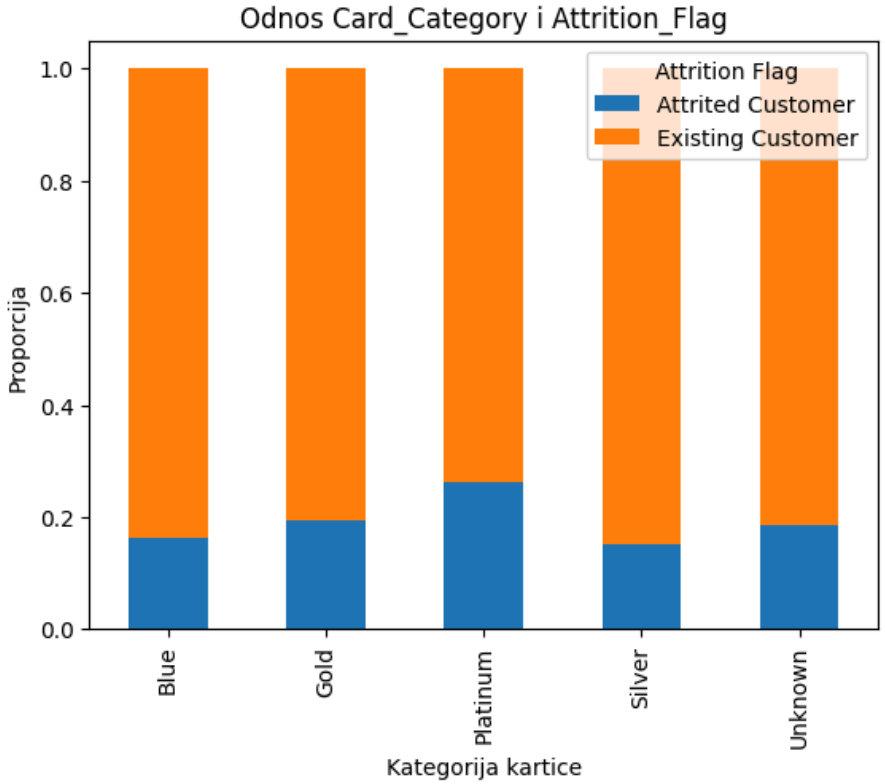
```
Card_Category_clean
Blue        9154
Silver       538
Unknown      303
Gold         113
Platinum      19
Name: count, dtype: int64
```

Slika 23: Prikaz distribucije za kolonu Card_Category

Na *slici 23* su prikazani rezultati raspodjele korisnika prema kategoriji kreditne kartice nakon proces čišćenja podataka. Najdominantniju kategoriju čine korisnici sa karticom tipa Blue. Kategorija Silver je znatno rjeđe zastupljena, dok su kartice Gold i Platinum prisutne u veoma malom broju. Prisustvo kategorije Unknown nam ukazuje da postoji manji broj zapisa kod kojih tip kartice nije bilo moguće odrediti.



Slika 24: Prikaz raspodjele korisnika prema kategoriji kreditne kartice



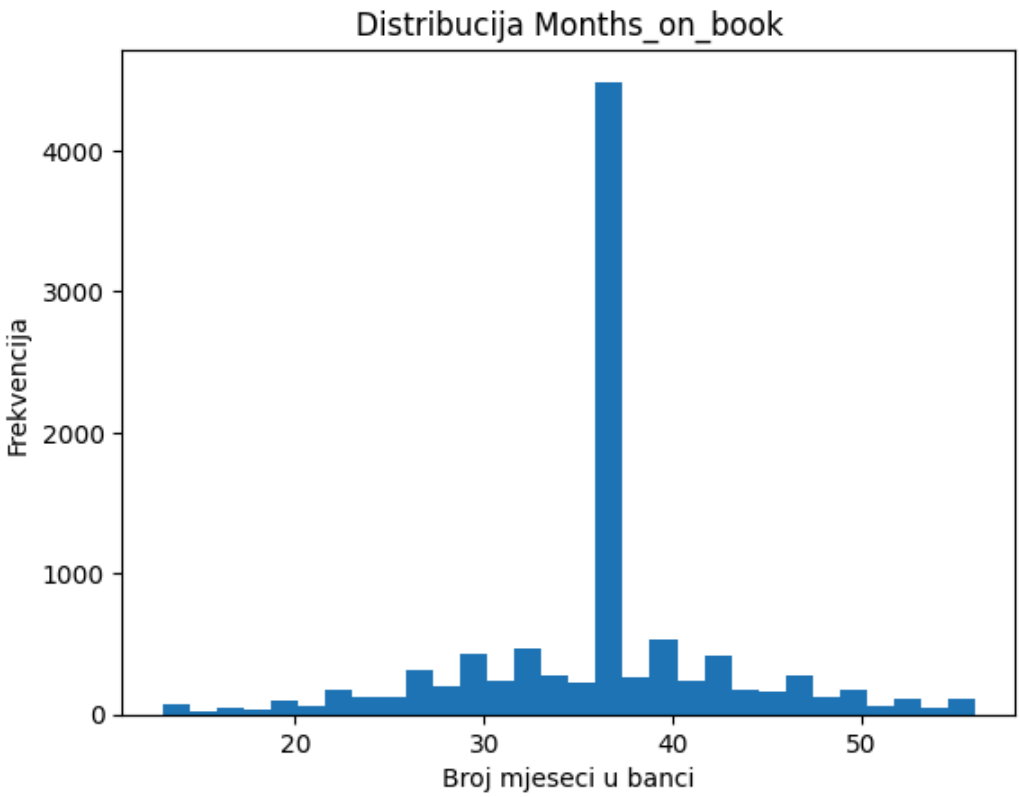
Slika 25: Prikaz odnosa između vrste kartice i statusa klijenta

Na *slici 25* prikazan je odnos između vrste kartice i statusa klijenta. Najveća stopa napuštanja banke primjetna je kod vlasnika Platinum kartica. Iako su Gold i Platinum klijenti najcijenjeniji za banku, ovakvi podaci sugeriraju da je upravo ovaj segment i najrizičniji, što može ukazivati na to da premium usluge banke ne ispunjavaju očekivanja zahtijevnijih klijenata.

Kolona **Months_on_book** predstavlja broj mjeseci tokom kojih je klijent aktivan u banci. Analizom ove kolone utvrđene su engativne vrijednosti, ekstremno veliki brojevi, dodati specijalni simboli i nedostajuće vrijednosti. U prvom koraku je izvršeno uklanjanje svih nenumeričkih karaktera iz zapisa, nakon čega su vrijednosti konvertovane u numerički format. U drugom koraku su utvrđene određene granice tako da su sve negativne vrijednosti i vrijednosti veće od 100 mjeseci utvrđene kao neispravne i postavljene su na NaN. Kako bi se očuvao broj zapisa u skupu podataka, nedostajuće vrijednosti su imputirane medianom kolone, koja je robusna na prisustvo outliera. Nakon čišćenja, distribucija kolone je stabilna i realna, sa vrijednostima u rasponu od 13 do 56 mjeseci.

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean        35.941641
std          7.019558
min         13.000000
25%         34.000000
50%         36.000000
75%         38.000000
max         56.000000
Name: Months_on_book_clean, dtype: float64
```

Slika 26: Prikaz raspodjele distribucije za Months_on_book

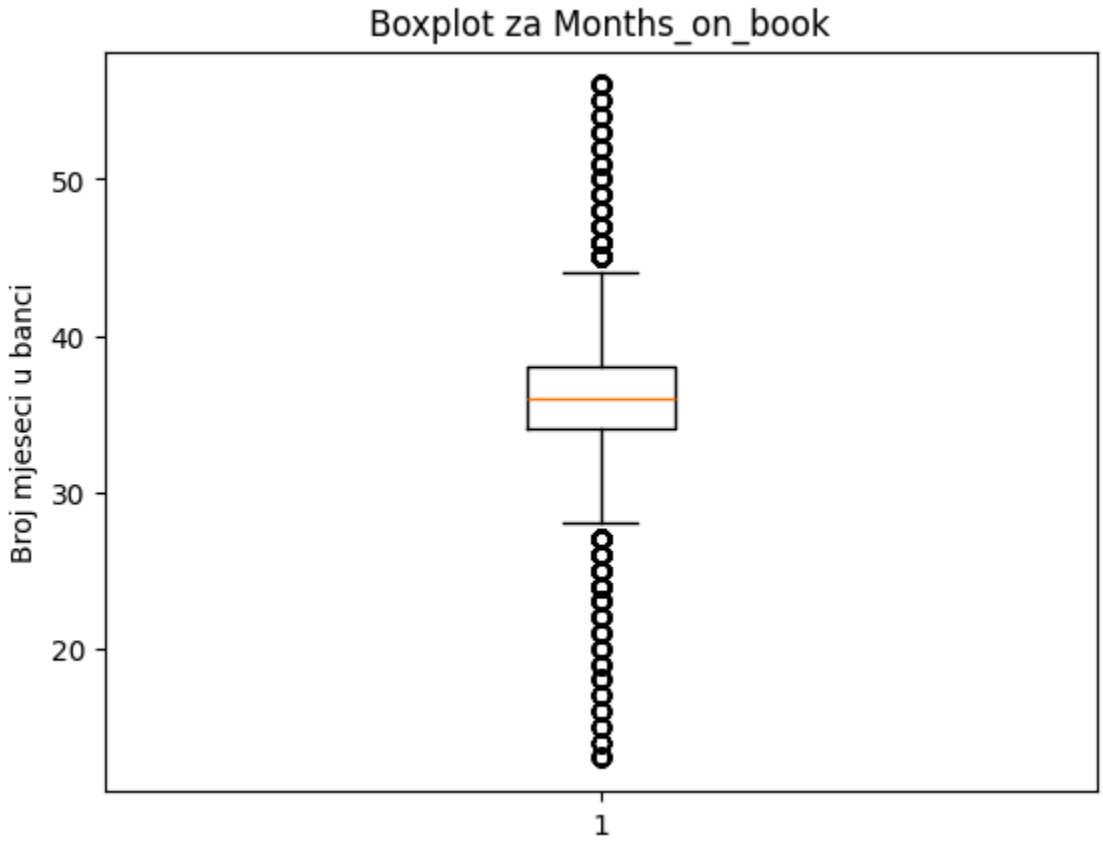


Slika 27: Histogram raspodjele broja mjeseci koje su korisnici proveli u banci

Histogram *(slika 27)* prikazuje raspodjelu broja mjeseci koje su korisnici proveli u banci. Najveća koncentracija vrijednosti se nalazi oko 36 mjeseci, što ukazuje da značajan broj korisnika ima približno tri godine odnosa sa bankom. Izrazito visoka frekvencija na toj vrijednosti posljedica je imputacije medijanom, jer su nevalidne i nedostajuće vrijednosti zamijenjene centralnom vrijednošću.

Distribucija pokazuje širok raspon vrijednosti**,** približno od 15 do 55 mjeseci, pri čemu je većina korisnika koncentrisana u intervalu između 25 i 45 mjeseci**.** Na lijevoj i desnoj strani histograma prisutne su rjeđe vrijednosti, što ukazuje na umjerenu asimetriju distribucije, ali bez ekstremnih ili nerealnih odstupanja.

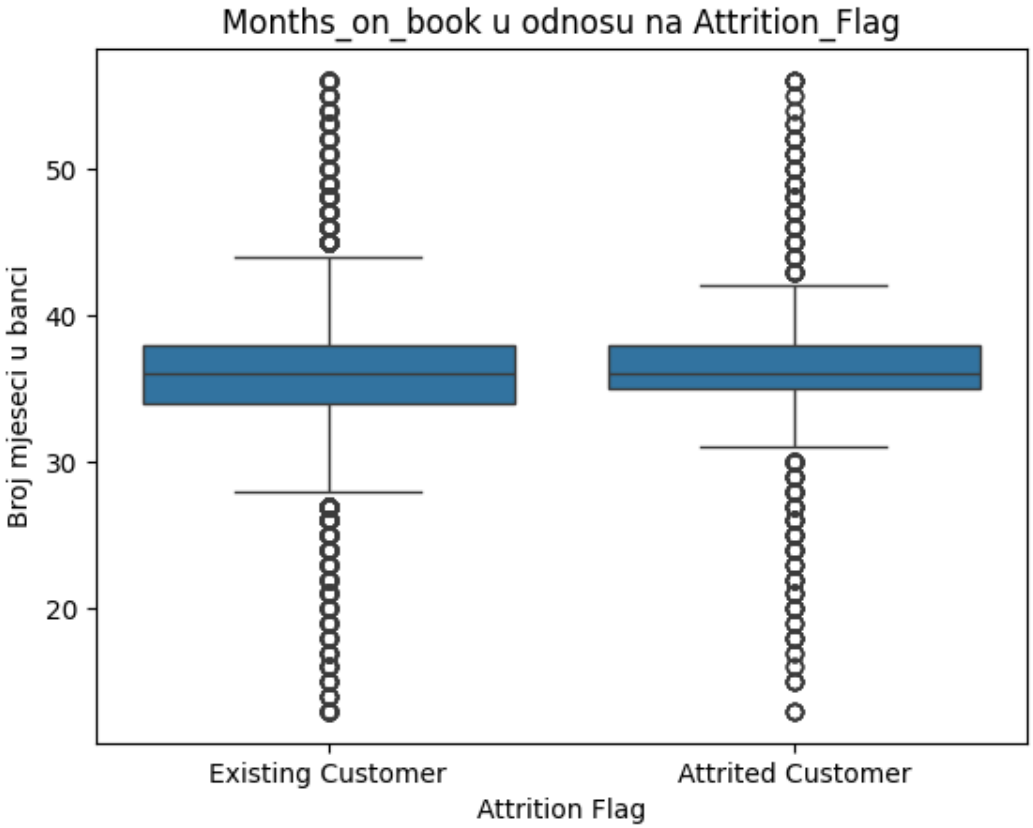
Ukupno gledano, histogram potvrđuje da varijabla *Months_on_book_clean* ima realnu i stabilnu raspodjelu, dok izraženi pik oko medijane odražava primijenjeni postupak imputacije.



Slika 28 *:* Boxplot varijable Months_on_book

Boxplot *(slika 28)* potvrđuje medijanu oko 36 mjeseci. Interkvartilni raspon obuhvata vrijednosti između 34 i 38 mjeseci približno, što ukazuje na relativno malu varijabilnost među srednjih 50% podataka. Outlieri predstavljaju korisnike sa znatno kraćim ili znatno dužim periodom članstva, ali se i dalje nalaze u realnim i očekivanim granicama. Prisutnost većeg broja outliera je

djelimično posljedica imputacije medijanom, koja je povećala koncentraciju vrijednosti u centralnom dijelu distribucije.



Slika 29: Odnos varijabli Months_on_book i Attrition_Flag

Na *slici 29* može se uočiti da su medijane obje grupe veoma slične, što daje zaključak da prosječna dužina odnosa sa bankom nike značajno različita između korisnika koji su ostali i onih koji su napustili uslugu. Može se primijetiti da je nešto veća raspršenost vrijednosti kod korisnika koji su napustili uslugu, posebno u donjem dijelu distribucije gdje se pojavljuje veći broj korisnika sa kraćim trjanjem odnosa usluga. Ovo može ukazivati da kraći period članstva blago povećava vjerovatnoću napuštanja usluge, iako ova razlika nike toliko izražena.

Kolona **Total_Relationship_Count** sadrži podatak o ukupnom broju proizvoda i usluga koje klijent koristi u banci. Analizom je utvrđeno da kolona sadrži negativne vrijednosti, ekstremno velike brojeve, kao i zapise sa dodatnim znakovima, odnosno specifičnim simbolima koej nemaju realno značenje. U procesu čišćenja su iz kolone prvo uklonjeni svi nenumerički karakteri, nakon čega su vrijednosti konvertovane u numerički format. Postavljena su logička ograničenja prema kojima broj ne može biti negativan niti veći od 10, pa su sve takve vrijednosti označene kao nedostajuće. Nedostajući podaci su potom zamijenjeni medianom kolone. Nakon čišćenja, vrijednosti kolone se kreću u rasponu od 1 do 6, sa medianom 4 i srednjom vrijednošću od 3.86, što ukazuje na realističnu i očekivanu raspodjelu broja bankarskih odnosa po klijentu.

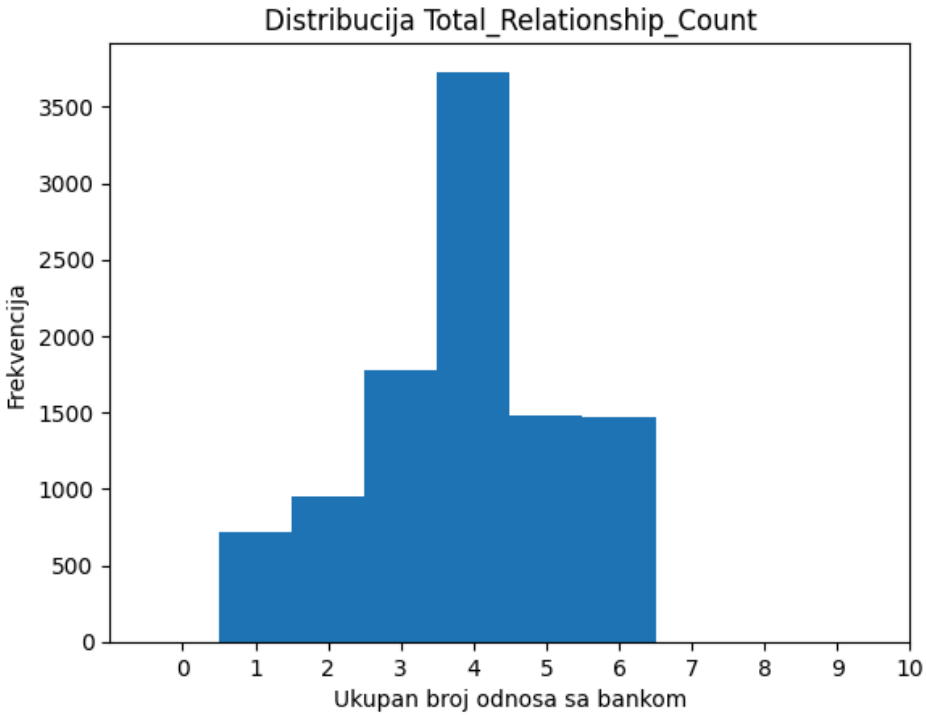
```
Deskriptivna statistika poslije čišćenja:
count    10127.000000
mean         3.858793
std          1.376924
min          1.000000
25%          3.000000
50%          4.000000
75%          5.000000
max          6.000000
Name: Total_Relationship_Count_clean, dtype: float64

Value counts:
Total_Relationship_Count_clean
1.0     717
2.0     955
3.0    1781
4.0    3729
5.0    1478
6.0    1467
Name: count, dtype: int64
```

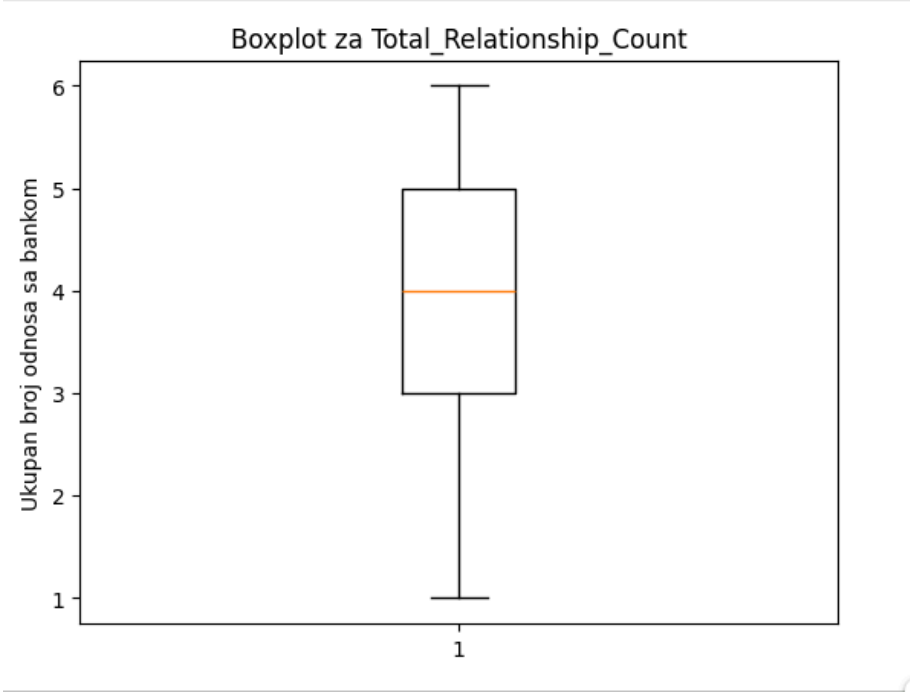
Slika 30 : Prikaz distribucije za Total_Relationship_Count

Na *slici 30* nakon čišćenja svi zapisi sadrže validne vrijednosti u realnom rasponu od 1 do 6. Deskriptivna statistika pokazuje da je prosječan broj odnosa približno 3.86, dok je medijana jednaka 4, što ukazuje da većina korisnika ima četiri aktivna odnosa sa bankom. Interkvartilni

raspon obuhvata vrijednosti između 3 i 5, što znači da se srednjih 50% korisnika nalazi unutar tog intervala. Distribucija vrijednosti pokazuje da je najčešća vrijednost 4, dok su vrijednosti 3, 5 i 6 također značajno zastupljene. Manji broj korisnika ima samo jedan ili dva odnosa sa bankom. Ovakva raspodjela ukazuje da većina korisnika koristi više proizvoda ili usluga banke.

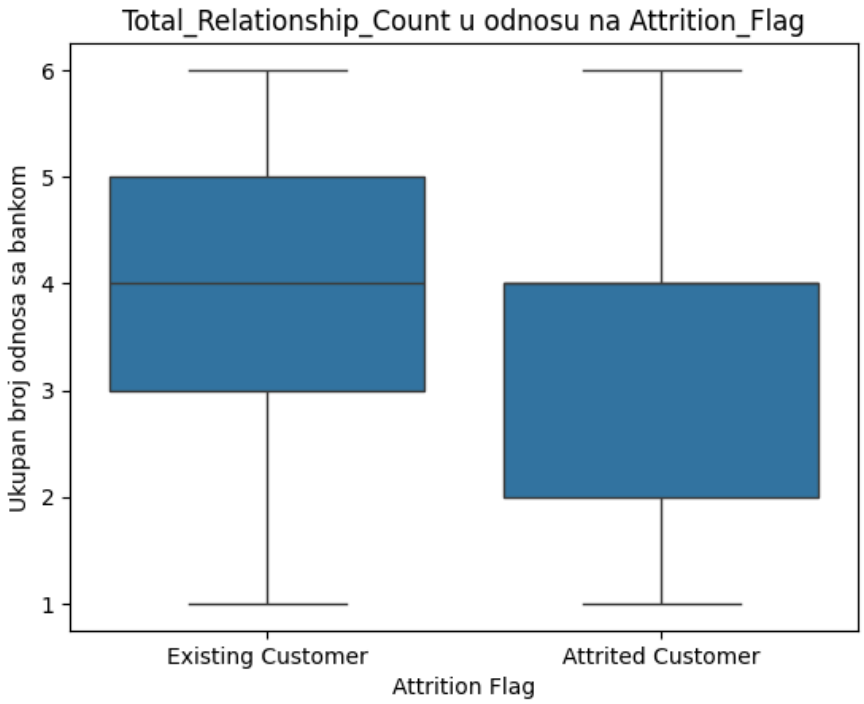


Slika 31: Hisotgram raspodjele ukupnog broja odnosa korisnika sa bankom



Slika 32: Boxplot za Total_Relationship_Count

Boxplot *(slika 32)* nam potvrđuje da medijana iznosi 4 i može se primijetit da je interkvartilni raspon od 3 do 5što ukazuje da se srednjih 50% korisnika nalazi unutar tog intervala. Na boxplotu nisu prisutni izraženi outlieri, što ukazuje da su sve vrijednosti unutar očekivanih i realnih granica. Ovakav raspored potvrđuje stabilnost varijable nakon procesa čišćenja



Slika 33: Boxplot raspodjele ukupnog broja odnosa sa bankom u odnosu na ciljnu varijablu

Na *slici 33* se uočava da postojeći korisnici u prosjeku imaju veći broj odnosa sa bankom u poređenju sa korisnicima koji su napustili uslugu. Medijana za postojeće korisnike iznosi 4, dok je kod korisnika koji su napustili uslugu niža, oko 3. Također, interkvartilni raspon kod postojećih korisnika pomjeren je ka većim vrijednostima, što ukazuje da srednjih 50% ove grupe koristi veći broj bankarskih proizvoda. Ovakvi rezultati nam sugerišu da veći broj odnosa sa bankom može biti povezan sa većom lojalnošću korisnika, dok korisnici sa manjim brojem proizvoda ili usluga imaju veću vjerovatnoću napuštanja usluge.

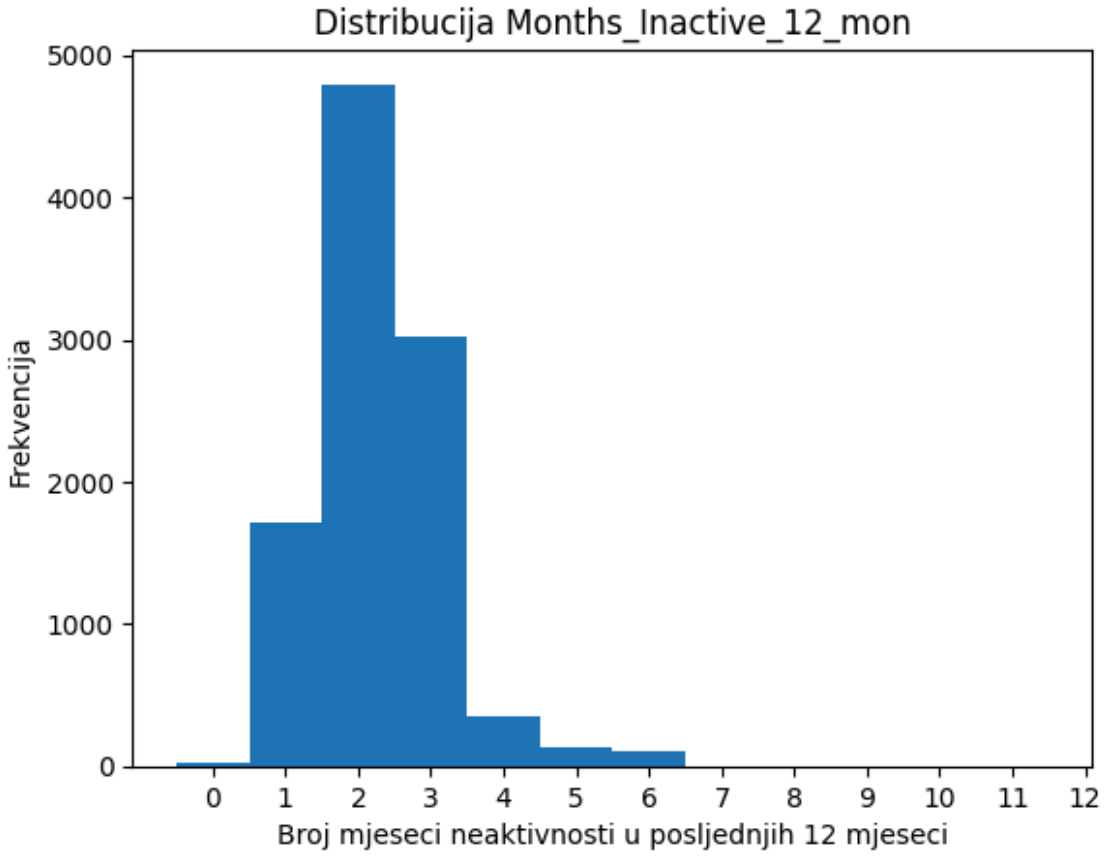
Kolona **Months_inactive_12_mon** predstavlja broj mjeseci u kojima je klijent bio neaktivan tokom posljednjih 12 mjeseci. Tokom analize uočene su nepravilnosti u zapisima, uključujući zapise sa specifičnim karakterima, negativne vrijednosti, ekstremno velike brojeve, koji ne odgovaraju realnim podacima, i nedostajuće vrijednosti. U prvom koraku su uklonjeni znakovi koji nisu numerički, nakon čega su vrijednosti konvertovane u numerički format. Zati msu primijenjene logičke granice, pri čemu su sve vrijednosti manje od 0 i veće od 12 mjeseci označene kao nevažeće i zamijenjene vrijednošću NaN. Na kraju su nedostajuće vrijednosti zamijenjene korištenjem medijane, kako bi se očuvala centralna tendencija podataka i smanjio uticaj outliera. Nakon čišćenja, vrijednosti u ovoj koloni se nalaze u rasponu od 0 do 6 mjeseci, pri čemu najveći broj klijenata ima između 1 i 3 mjeseca neaktivnosti.

- Opseg vrijednosti nakon čišćenja:
  Min: 0.0, Max: 6.0
  Months_Inactive_clean
  0.0 25
  1.0 1708
  2.0 4796
  3.0 3018
  4.0 347
  5.0 134
  6.0 99
  Name: count, dtype: int64

Slika 34: Prikaz distribucije za Months_inactive_12_mon

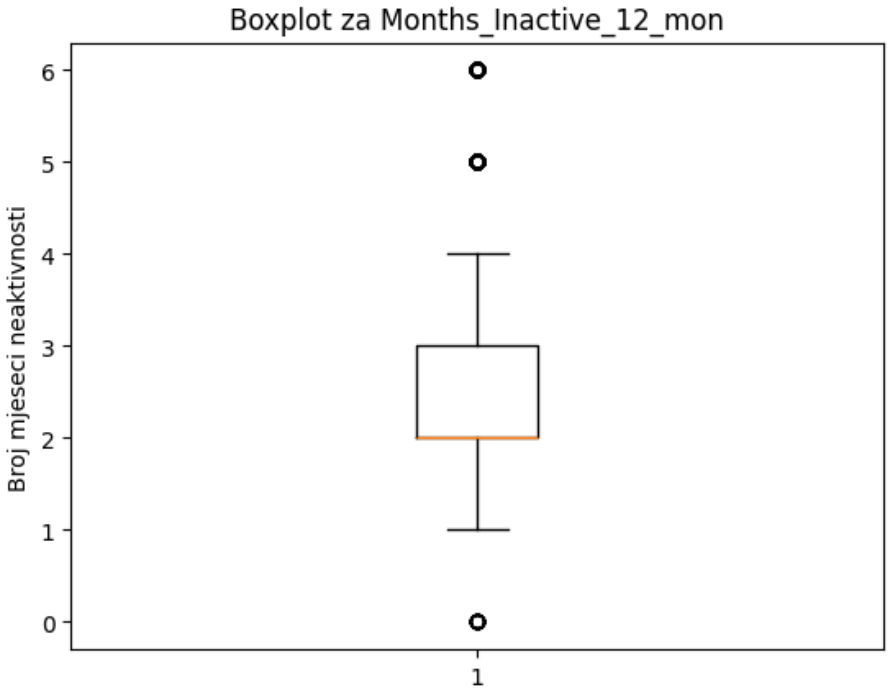
Nakon procesa čišćenja podataka, vrijednosti se nalaze u realnom rasponu od 0 do 6 mjeseci, što ukazuje da ekstremne i nerealne vrijednosti nisu prisutne u skupu podataka. Deskriptivna analiza nam pokazuje da većina korisnika ima između 1 i 3 mjeseca neaktivnosti, pri čemu je najčešća vrijednost 2 mjeseca, što pokazuje na umjerenu, ali povremenu neaktivnost korisnika.

Manji broj korisnika ima visok broj mjeseci neaktivnosti (4 ili više), dok je potpuno aktivnih korisnika (0 mjeseci neaktivnosti) malo. Ovo pokazuje da većina korisnika zadržava redovnu aktivnost tokom godine, dok produžena neaktivnost predstavlja rjeđi, ali potencijalno značajan slučaja koji može biti povezan sa većom vjerovatnoćom napuštanja usluge.



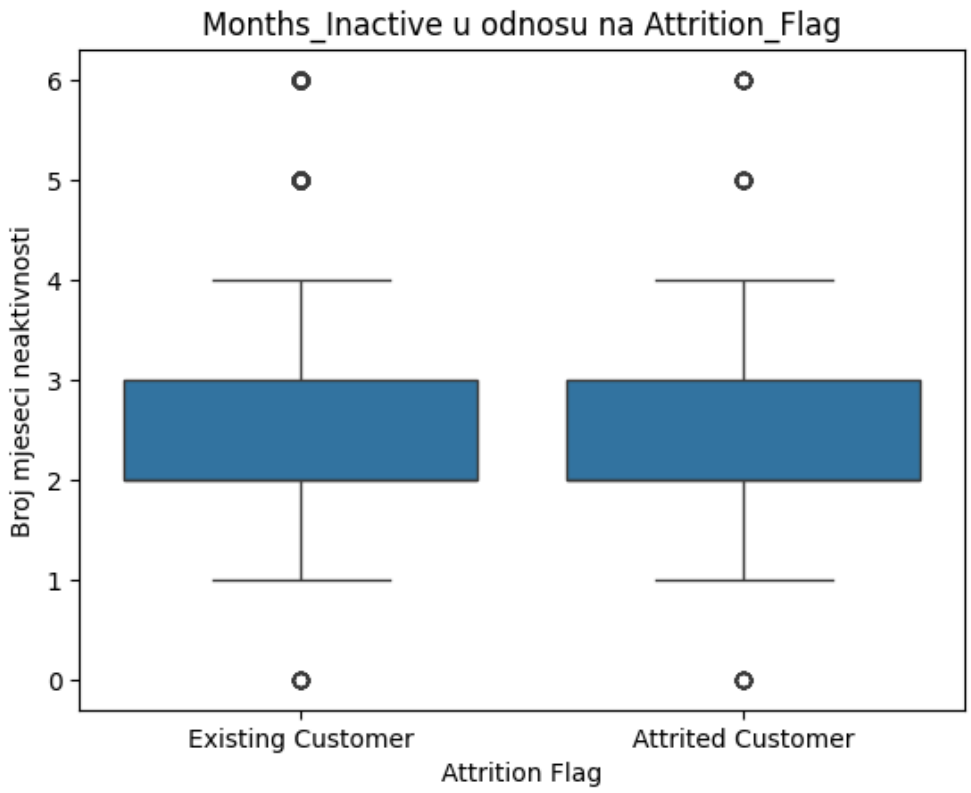
Slika 35: Histogram raspodjele broja mjeseci neaktivnosti korisnika u posljednjih 12 mjeseci

Na histogramu *(slika 35)* se mož primijetiti da je distribucija desno asimetrična sa opadajućom frekvencijom kako se broj mjeseci neaktivnosti povećava. Veći broj mjeseci neaktivnosti (4 i više) javlja se rijetko, što ukazuje da dugotrajna neaktivnost predstavlja izuzetak u ovom skupu podataka. Prisustvo manjih vrijednosti blizu nule pokazuje da postoji i dio korisnika koji su tokom cijele godine bili aktivni.



Slika 36: Boxplot za Months_Inactive_12_mon

Na *slici 36* boxplot prikazuje centralnu tendenciju varijable Months_Inactive_clean. Medijana iznosi 2 mjeseca, što potvrđuje da većina korisnika ima kratke periode neaktivnosti. Interkvartilni raspon obuhvata vrijednosti približno između 2 i 3 mjeseca, što ukazuje na relativno malu varijabilnost među srednjih 50% korisnika. Vrijednosti 0, 5 i 6 su označeni kao potencijalni outlieri. Ovi outlieri predstavljaju korisnike koji su bili ili potpuno aktivni tokom godine ili su imali duže periode neaktivnosti. Iako označeni kao outlieri, sve vrijednosti se nalaze unutar realnog i očekivanog raspona, pa ne ukazuju na greške u podacima.



Slika 37: Odnos varijabli Months_Inactive i ciljne varijable

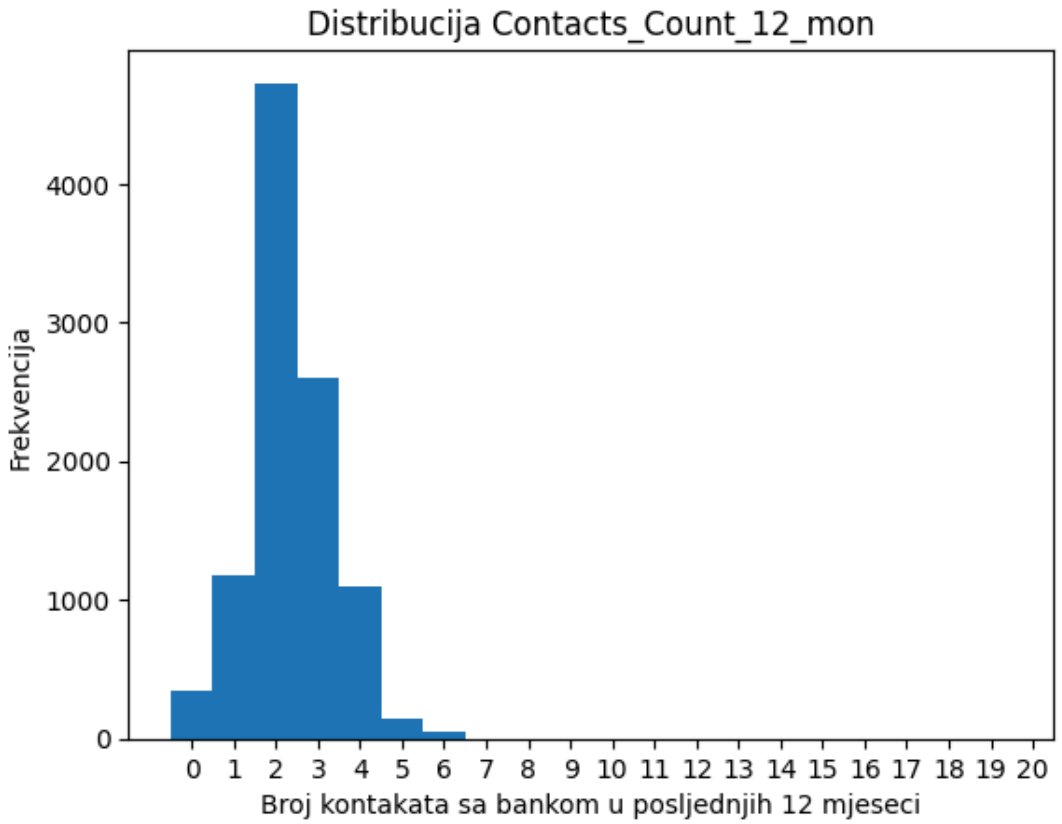
Na *slici 37* boxplot prikazuje raspodjelu broja mjeseci neaktivnosti u posljednjih 12 mjeseci u odnosu na ciljnu varijablu Attrition_Flag. Uočava se da medijana u obje grupe iznosi približno 2 mjeseca, a interkvartilni rasponi su gotovo identični, što ukazuje da većina korisnika, bez obzira na status, ima sličan nivo neaktivnosti. Iako korisnici koji su napustili uslugu pokazuju nešto veću raspršenost u gornjem dijelu distribucije, razlike između dvije grupe nisu izražene. Ovo sugeriše da varijabla *Months_Inactive_clean* sama po sebi nema snažnu diskriminatornu moć.

Kolona **Contacts_Count_12_mon** imala je raznovrsne promjene poput, tekstualnih zapisa, negativnih vrijednosti i ekstremnih vrijednosti koji nisu realni za broj kontakata sa bankom u posljednjih 12 mjeseci. U prvom koraku su uklonjeni svi nenumerički karakteri, nakon čega je kolona konvertovana u numerički format . Vrijednosti manje od 0 i veće od 20 su tretirane kao greške i zamijenjene su nedostajućim vrijednostima. Nedostajući podaci su potom zamijenjeni medianom kolone, čime je očuvana realna distribucija podataka što se može vidjeti i samom analizom nakon čišćenja ove kolone. Vrijednosti, nakon čišćenja, se kreću u rasponu od 0 do 6, pri čemu je najčešći broj kontakata 2.

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean         2.351832
std          1.009995
min          0.000000
25%          2.000000
50%          2.000000
75%          3.000000
max          6.000000
Name: Contacts_Count_clean, dtype: float64
Contacts_Count_clean
0.0     341
1.0    1172
2.0    4726
3.0    2599
4.0    1095
5.0     148
6.0      46
Name: count, dtype: int64
```

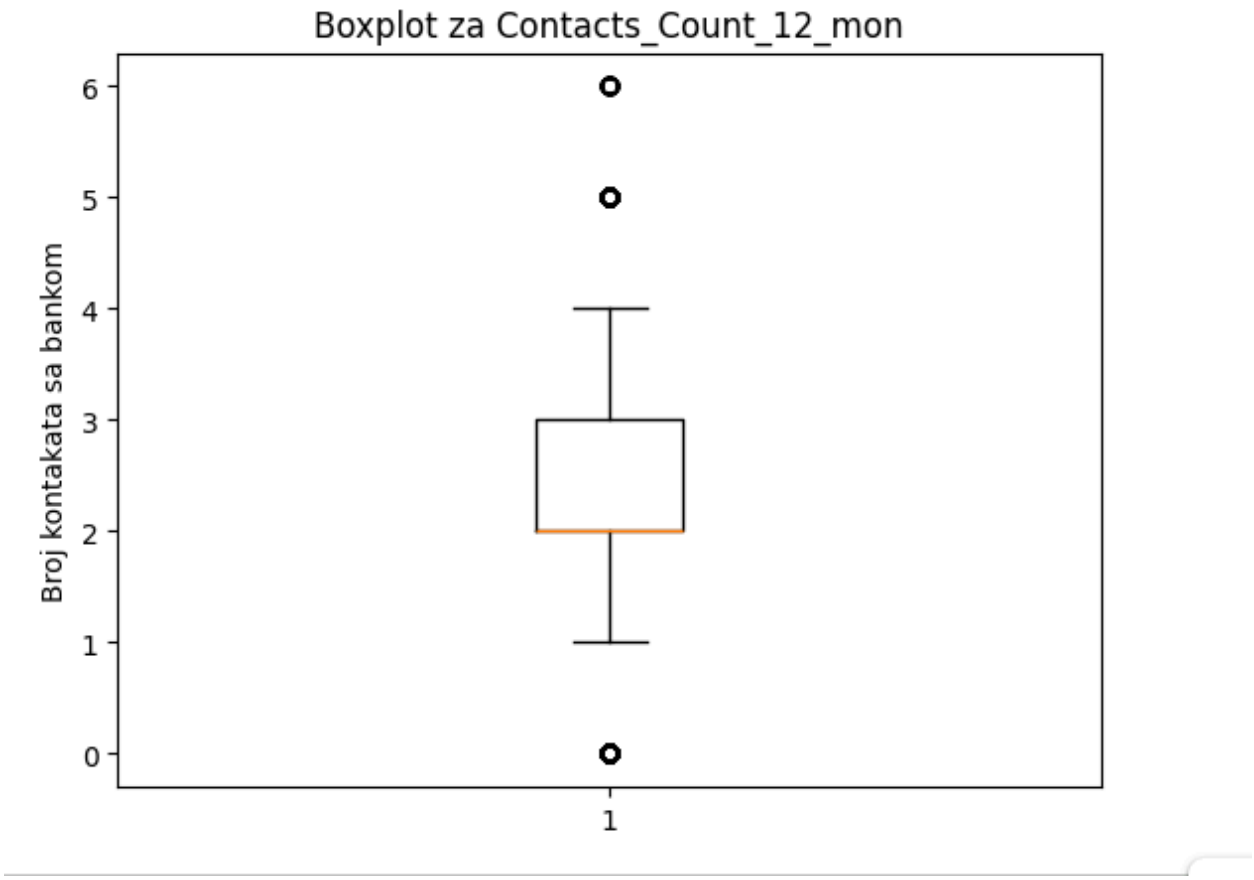
Slika 38: Prikaz distribucije za Contacts_Count_12_mon

Nakon procesa čišćenja podataka, vrijednosti se nalaze u realnom rasponu od 0 do 6 kontakata, bez prisustva ekstremnih zapisa. Deskriptivna statistika pokazuje da je prosječan broj kontakata približno 2.35, dok je medijana jednaka 2, što ukazuje da većina korisnika tokom godine ima ograničen broj interakcija sa bankom. Distribucija vrijednosti pokazuje da je najčešća vrijednost 2 kontakta, dok su vrijednosti 1 i 3, također, zastupljene. Manji broj korisnika ima 4 ili više kontakata sa bankom, a potpuno odsustvo kontakata se rijetko pojavljuje. Ovo ukazuje da većina korisnika komunicira sa bankom povremeno.



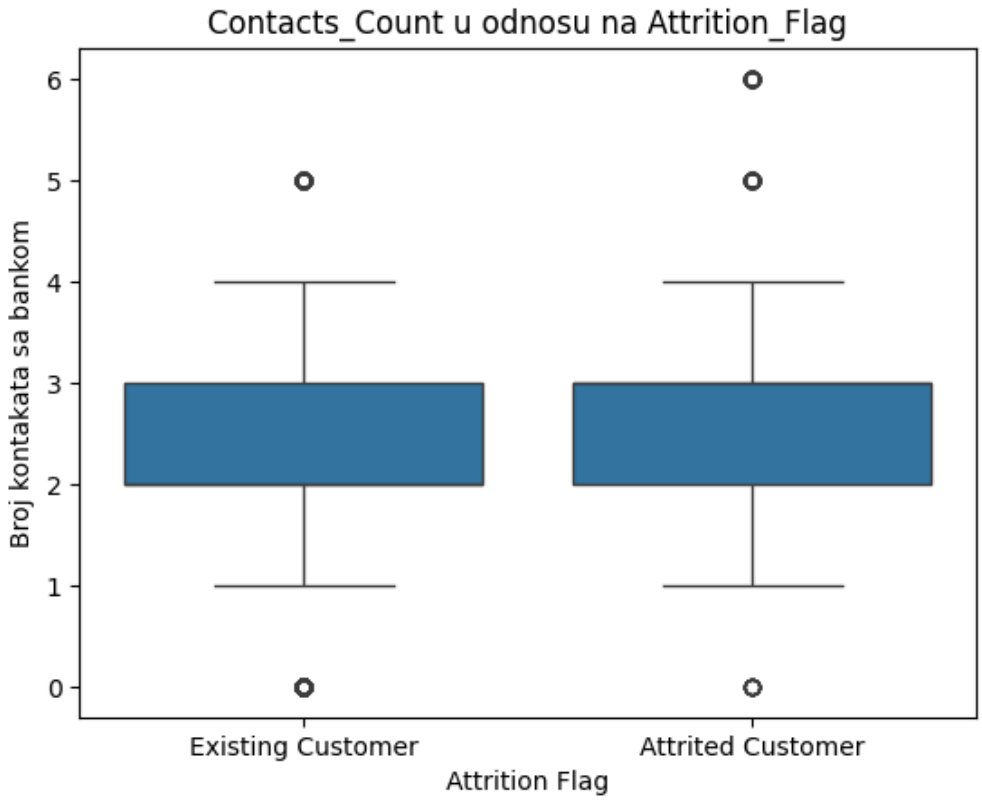
Slika 39: Histogram raspodjele broja kontakata korisnika sa bankom u posljednjih 12 mjeseci

Sa *slike 39* može se uočiti da je distribucija desno asimetrična sa opadajućom frekvencijom kako se broj kontakata povećava. Vrijednosti veće od 4 kontakta pojavljuju se rijetko, dok su veoma visoki brojevi kontakata gotovo odsutni, što potvrđuje da učestala komunikacija sa bankom nije tipična za većinu korisnika.



Slika 40: Boxplot za Contacts_Count_12_mon

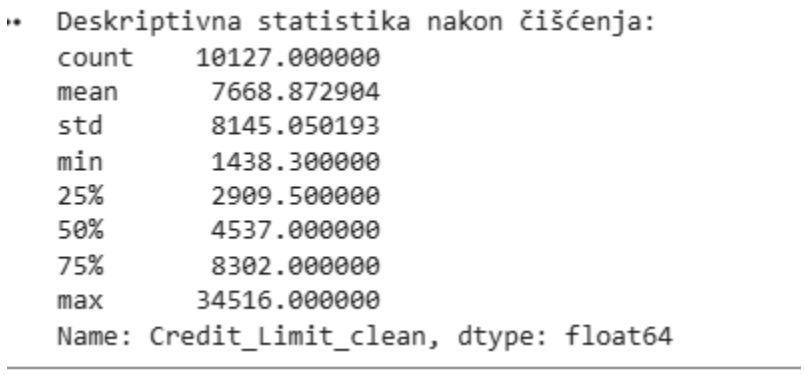
Na *slici 40* boxplot prikazuje centralnu tendenciju varijable Contacts_Count_clean. Medijana iznosi 2 kontakta, što potvrđuje da većina korisnika ima mali broj interakcija sa bankom. Interkvartilni raspon obuhvata vrijednosti približno između 2 i 3 kontakta, što ukazuje na relativno malu varijabilnost među srednjih 50% korisnika. Vrijednosti 0, 5 i 6 kontakata su označene kao potencijalni outlieri, ali obzirom da se nalaze u očekivanom rasponu ove vrijednosti ne ukazuju na greške u podacima.



Slika 41: Prikaz odnosa varijable Contacts_Count i ciljne varijable

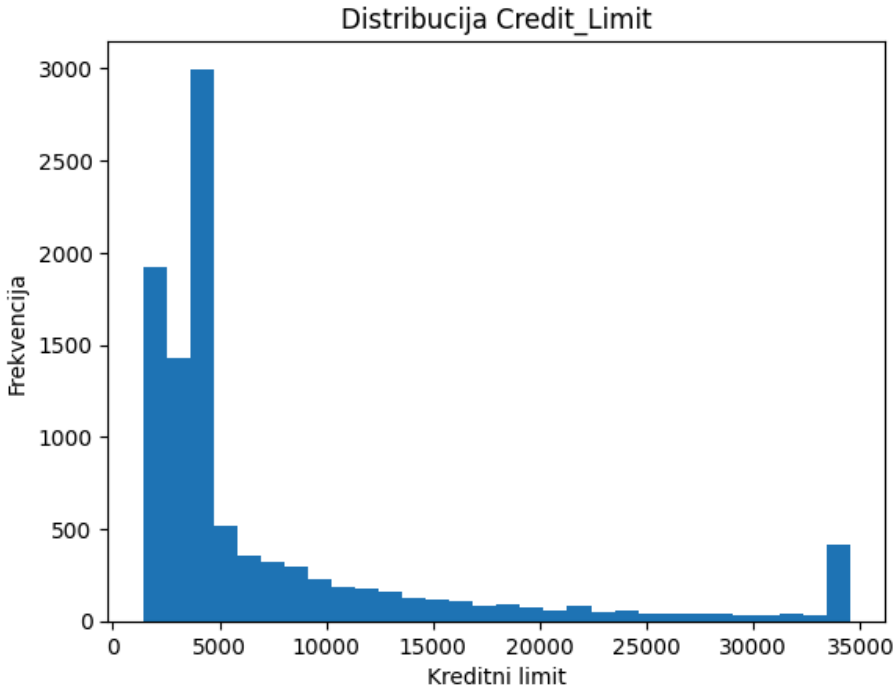
Boxplot *(slika 41)* prikazuje raspodjelu broja kontakata koje su korisnici ostvarili sa bankom u posljednjih 12 mjeseci u odnosu na ciljnu varijablu Attrition_Flag. Može se vidjeti da su medijane u obje grupe jednake i iznose približno 2 kontakta, dok su interkvartilni rasponi gotovo identični, što ukazuje da većina korisnika, bez obzira na status, ostvaruje sličan broj kontakata sa bankom. Može se zaključiti da analizirana varijabla nema snažnu individualnu povezanost sa ciljnom varijablom.

Analizom kolone **Credit_Limit** utvrđeno je da sadrži specifične karaktere, nerealno velike iznose, kao i negativne vrijednosti. Prvo su uklonjeni svi nenumerički karakteri, nakon čega su vrijednosti konvertovane u numerički format. Sve nelogične vrijednosti, kao što su negativne i ekstremno velike vrijednosti su označene kao nedostajuće. A zatim su nedostajuće vrijednosti zamijenjene medianom kolone kako bi se očuvala robusnost distribucije. Nakon čišćenja, kreditni limiti se kreću u realnom rasponu između 1 400 do 34 500 sa medianom približno 4 500.



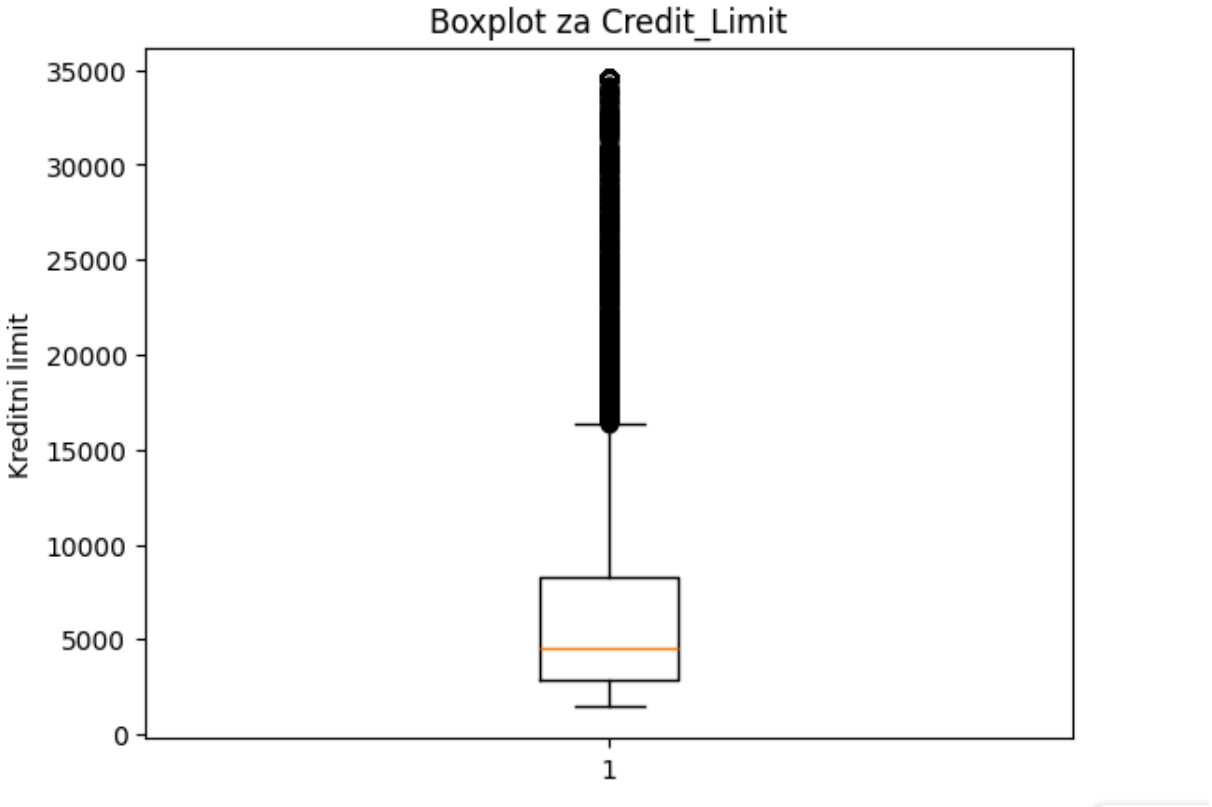
Slika 42: Prikaz distribucije za Credit_Limit

Na *slici 42* se može vidjeti da nakon procesa čišćenja ove kolone sve vrijednosti se nalaze u očekivanom rasponu, bez prisustva nerealnih ili ekstremnih vrijednosti. Deskriptivna statistika pokazuje da je prosječan kreditni limit oko 7 669, dok medijana iznosi približno 4 537, što ukazuje na desno asimetričnu distribuciju. Interkvartilni raspon se proteže od približno 2 910 do 8 302, što znači da se srednjih 50% korisnika nalazi unutar tog intervala. Minimalna vrijednost iznosi oko 1 438, dok maksimalna vrijednost dostiže 34 516, što ukazuje na značajnu varijabilnost kreditnih limita među korisnicima. Relativno visoka standardna devijacija dodatno potvrđuje heterogenost ove varijable, što sugeriše da kreditni limit može predstavljati važan faktor u analizi ponašanja korisnika i potencijalno imati uticaj na napuštanje usluge.



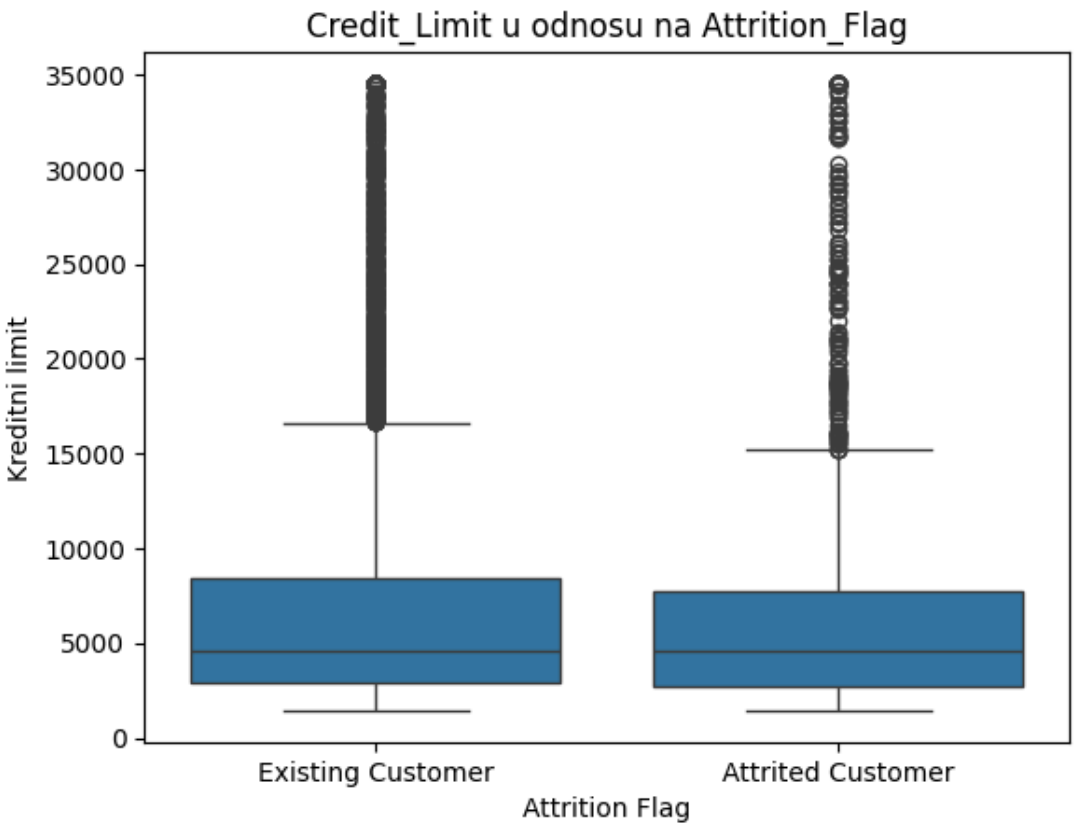
Slika 43: Histogram raspodjele kreditnih limita korisnika

Na histogramu *(slika 43)* može se primijetiti da je najveća koncentracija vrijednosti u nižem rasponu kreditnih limita, otprilike između 1.500 i 6.000, što ukazuje da većina korisnika raspolaže umjerenim kreditnim iznosima. Kako se vrijednost kreditnog limita povećava, frekvencija zapisa se postepeno smanjuje. Distribucija je prilično desno asimetrična, sa dugim repom prema višim vrijednostima. Manji broj korisnika ima visoke kreditne limite, koji dostižu i preko 30.000, što objašnjava značajnu razliku između prosječne vrijednosti i medijane. Ovakva raspodjela ukazuje na veliku heterogenost među korisnicima i potvrđuje da kreditni limit predstavlja varijablu sa značajnim rasponom.



Slika 44: Boxplot za Credit_Limit

Na *slici 44* boxplot prikazuje centralnu tendenciju, rasipanje i potencijalne ekstremne vrijednosti varijable Credit_Limit. Medijana kreditnog limita iznosi oko 4 500, što ukazuje da polovina korisnika ima kreditni limit manji, a polovina veći od ove vrijednosti. Interkvartilni raspon se prostire približno od 3 000 do 8 300, što pokazuje da se srednjih 50% korisnika nalazi u relativno širokom, ali realnom rasponu kreditnih limita. Iznad 16 000 se pojavljuje veći broj outliera, koji predstavljaju korisnike sa znatno višim kreditnim limitima, ali se ovi zapisi nalaze unutar dozvoljenog raspona, pa ukazuju na postojanje manjeg broja korisnika sa visokim kreditnim kapacitetom.



Slika 45: Odnos varijable Credit_Limit sa ciljnom varijablom

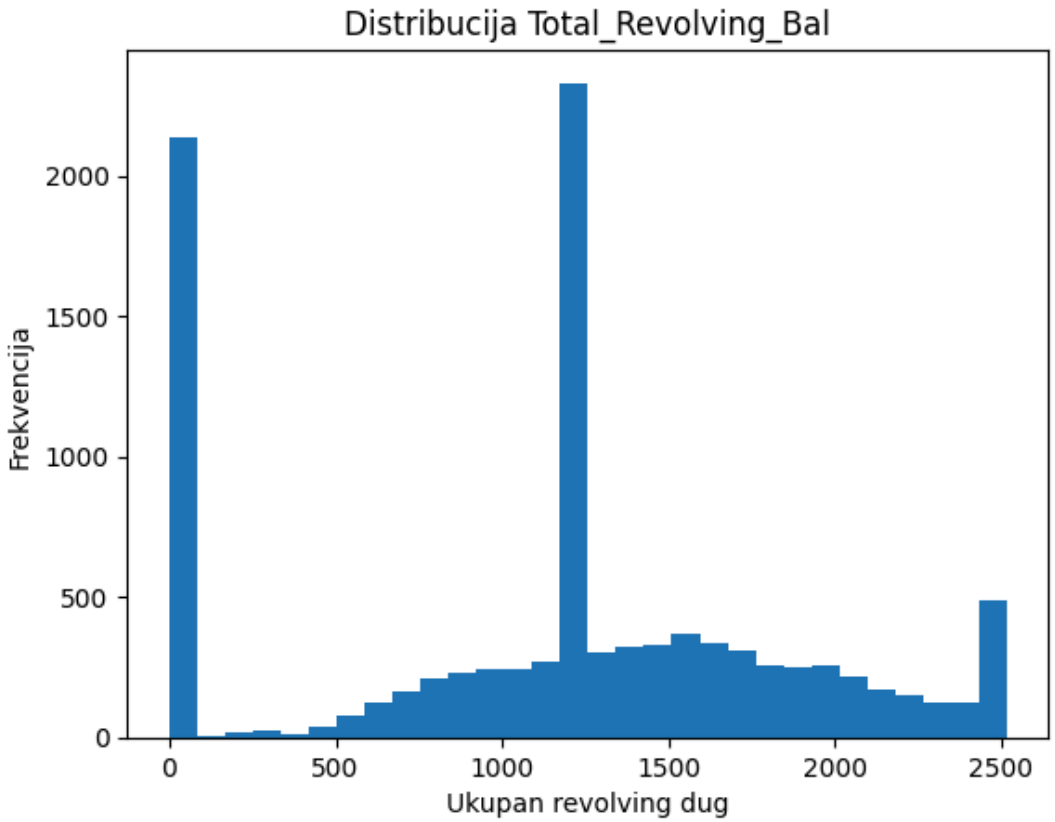
Na *slici 45* može se primijetiti da su medijane kreditnog limita u obje grupe slične, što ukazuje da prosječni kreditni kapacitet ne predstavlja značajnu razliku između korisnika koji ostaju i onih koji napuštaju uslugu. Interkvartilni rasponi su također uporedivi, iako postojeći korisnici pokazuju blago veći raspon prema višim vrijednostima, što sugeriše da među njima postoji nešto veći broj korisnika sa višim kreditnim limitima. Obzirom da obje grupe sadrže značajan broj outliera sa visokim kreditnim limitima, može se zaključiti kolika je heterogenost ove varijable.

Kod kolone **Total_Revolving_Bal** su uočene negativne numeričke vrijednosti, tekstualni zapisi i esktremno veliki iznosi. U procesu čišćenja uklonjeni su svu nenumerički karakteri, nakon čega su podacu konvertovani u numerički format. Negativne vrijednosti i visoki iznosi (iznosi koji su veći od 50 000) su označeni kao nedostajući podaci, jer ne predstavljaju validan dug. Nedostajuće vrijednosti su zamijenjene medianom kolone. Nakon čišćenja vrijednosti ove kolone su između 0 i 2 517. Medijana je 1249 i ona je nešto veća u odnosu na srednju vrijednost od 1155.9, što ukazuje na blagu asimetriju distribucije i prisustvo većeg broja klijenata sa nižim revolving dugom. Standardna devijacija 739.85 što ukazuje na umjerenu varijabilnost podataka.

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean      1155.887528
std        739.854987
min          0.000000
25%        725.000000
50%       1249.000000
75%       1637.500000
max       2517.000000
Name: Total_Revolving_Bal_clean, dtype: float64
```

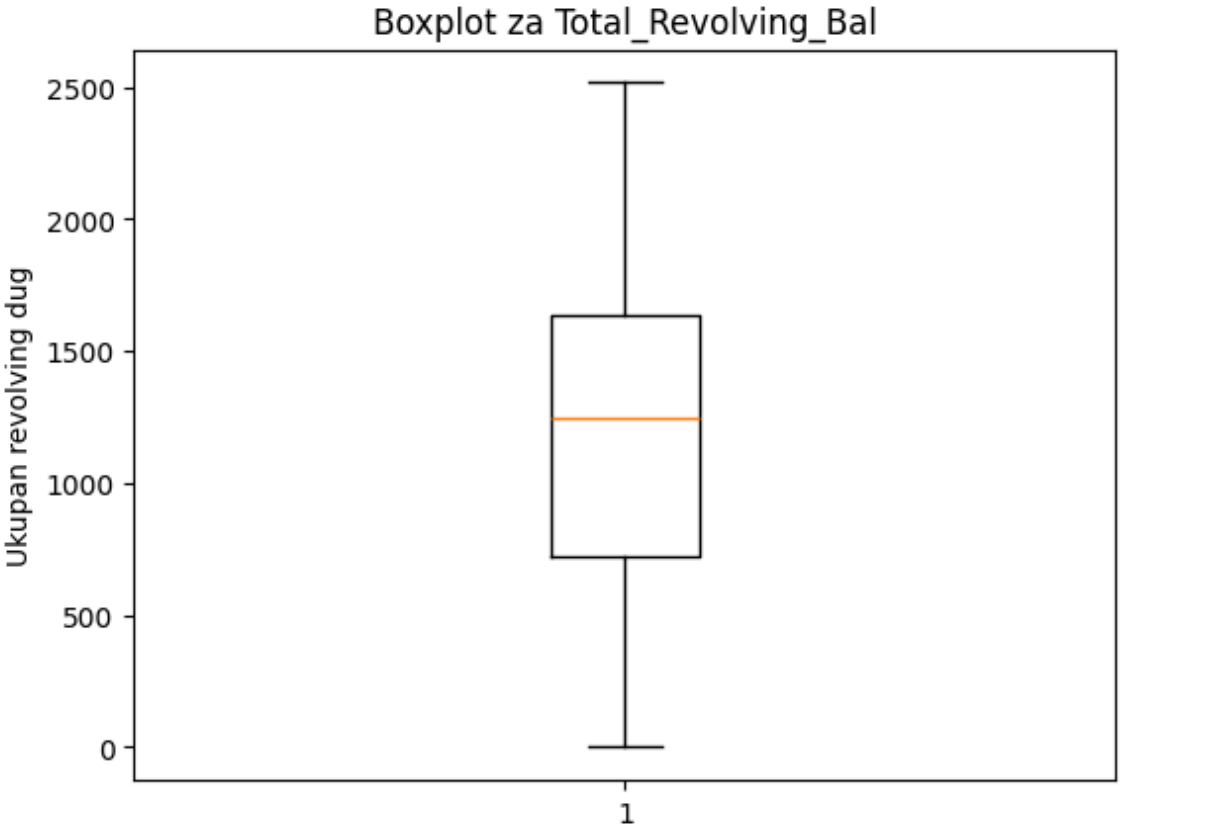
Slika 46: Prikaz distribucije za Total_Revolving_Bal

Na *slici 46* se nakon procesa čišćenja podataka sve vrijednosti nalaze u realnom i očekivanom opsegu, bez prisustva bilo kakvih ekstremnih ili nerealnih vrijednosti. Deskriptivna statistika pokazuje da je prosječan revolving dug oko 1 159, dok medijana iznosi približno 1 249, što ukazuje na blago lijevo asimetričnu distribuciju, gdje dio korisnika ima veoma nizak ili nulti dug. Interkvartilni raspon se prostire od 725 do 1 637, što znači da se srednjih 50% korisnika nalazi unutar tog intervala. Minimalna vrijednost iznosi 0, što ukazuje da određeni broj korisnika uopšte ne koristi revolving kredit, dok maksimalna vrijednost od 2 517 pokazuje da manji dio korisnika ima znatno veći iznos duga. Relativno visoka standardna devijacija ukazuje na izraženu varijabilnost među korisnicima, što sugeriše da iznos revolving duga može predstavljati značajan faktor u analizi finansijskog ponašanja



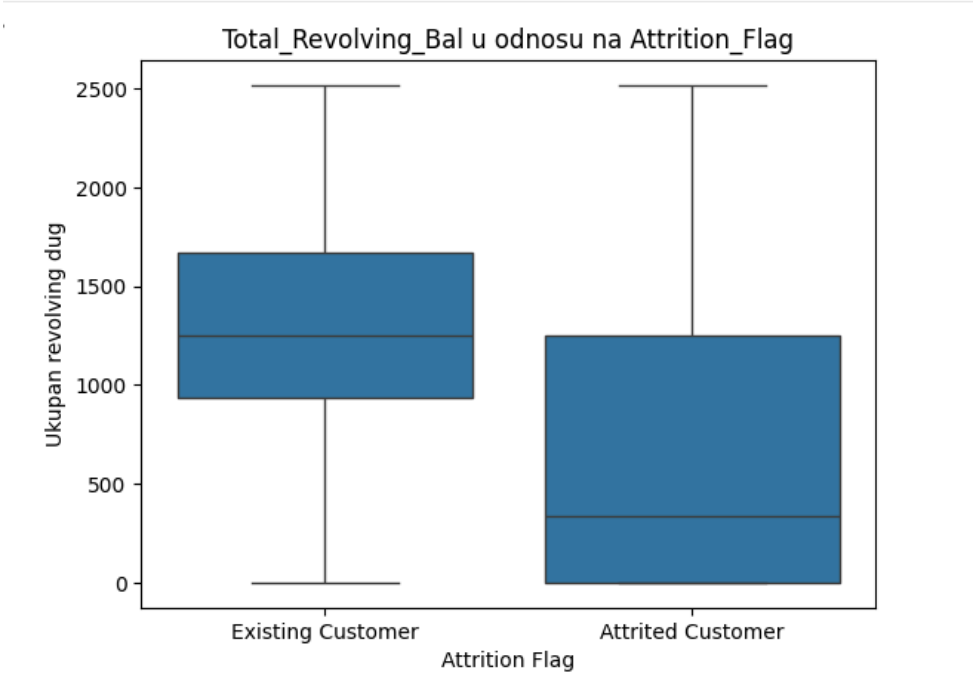
Slika 47: Histogram raspodjele ukupnog revolving duga korisnika

Na slici 47 Uočava se izražen vrh na vrijednosti blizu nule, što ukazuje da značajan broj korisnika nema revolving dug ili ga vrlo rijetko koristi. Drugi izraženiji dio distribucije nalazi se u intervalu približno 1 000 do 2 000, gdje se nalazi najveći broj korisnika sa aktivnim revolving dugom. Distribucija je nesimetrična i pokazuje asimetriju udesno, s dužim repom prema većim vrijednostima duga, što bi značilo da manji broj korisnika ima znatno veće iznose revolving duga. Također, primijeti se da ne postoji ravnomjerna raspodjela vrijednosti, već su podaci grupisani oko određenih iznosa, što može biti posljedica načina korištenja kreditnih limita i bankarskih proizvoda.



Slika 48: Boxplot za Total_Revolving_Bal

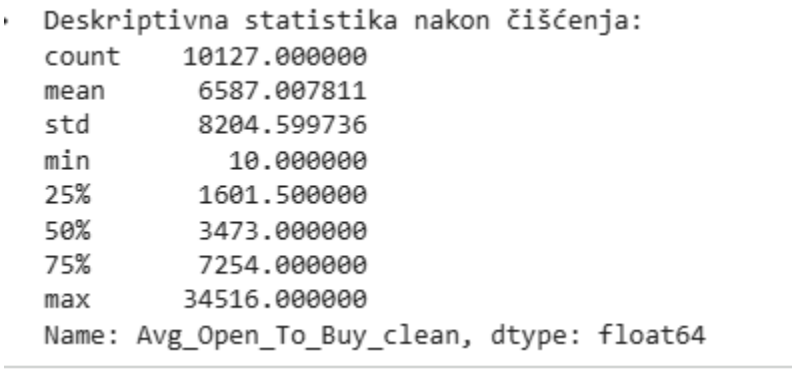
Boxplot na *slici 48* prikazuje raspodjelu ukupnog revolving duga korisnika i omogućava uvid u centralne vrijednosti, raspon i eventualna odstupanja. Medijana revolving duga iznosi približno 1 250, što znači da polovina korisnika ima dug manji, a polovina veći od ove vrijednosti. Interkvartilni raspon (IQR) se nalazi otprilike između 700 i 1 650, što ukazuje da se najveći broj korisnika nalazi unutar ovog intervala. Distribucija je blago asimetrična prema višim vrijednostima, što je u skladu s histogramom i sugeriše da manji broj korisnika ima znatno veće iznose duga.



Slika 49: Odnos Total_Revolving_Bal sa ciljnom varijablom

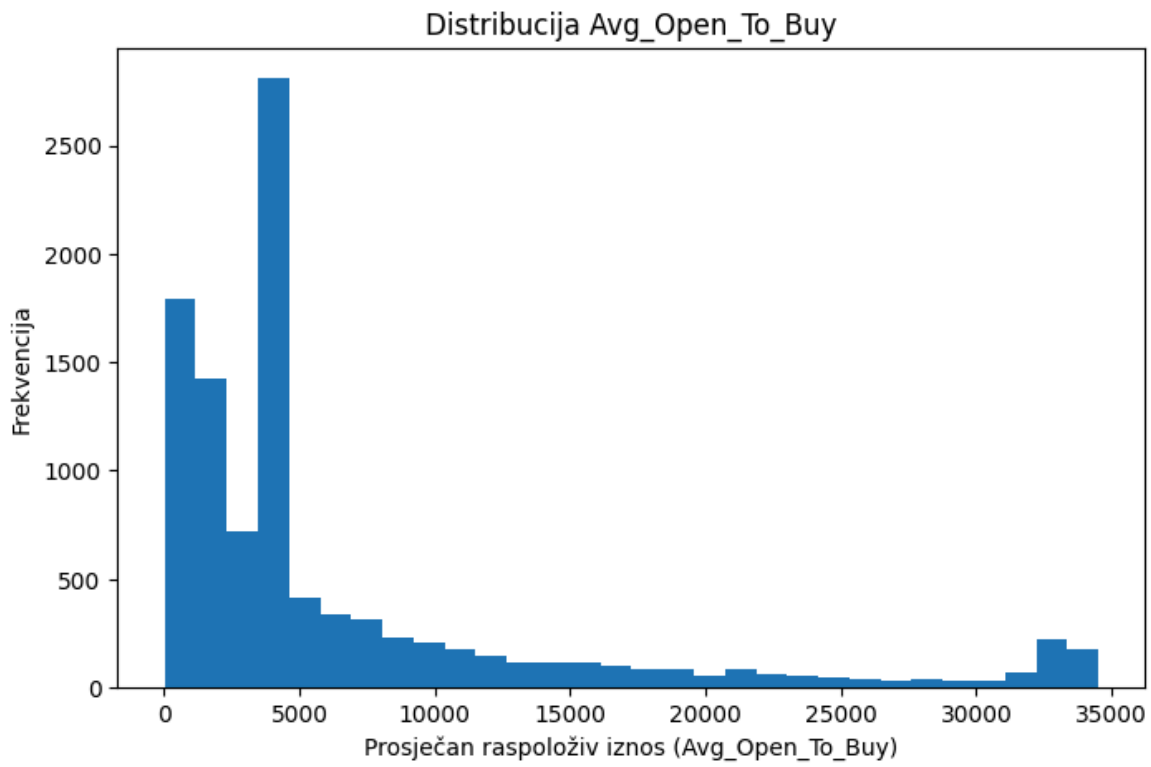
Na *slici 49* boxplotom se uspoređuje raspodjelu ukupnog revolving duga između postojećih i odlazećih korisnika. Uočava se da postojeći korisnici (Existing Customer) imaju znatno višu medijanu revolving duga, koja iznosi približno 1 200, dok je kod odlazećih korisnika (Attrited Customer) medijana značajno niža, oko 300. Interkvartilni raspon kod postojećih korisnika je uži i pomjeren ka višim vrijednostima, što ukazuje na stabilnije i konzistentnije korištenje revolving kredita. Dok je kod odlazećih korisnika prisutan širi raspon vrijednosti, sa velikim brojem korisnika koji imaju vrlo nizak revolving dug, što može značiti da je smanjen aktivnost ili postoji slabija povezanost sa kreditnim proizvodima banke. Iako obje grupe sadrže korisnike sa visokim iznosima revolving duga, ovakvi slučajevi su rjeđi kod odlazećih korisnika. Ova razlika sugeriše da je niži revolving dug potencijalno povezan sa većom vjerovatnoćom odlaska klijenta i da ova varijabla ima značajan diskriminativni potencijal u analizi *Attrition_Flag*.

Kolona **Avg_Open_To_Buy** je sadržavala numeričke i tekstualne vrijednosti, uključujući specijalne znakove i ekstremno velike vrijednosti. Tokom čišćenja su uklonjeni svi nenumerički karakteri, a podaci su konvertovani u numerički format. Negativne i ekstremno visoke vrijednosti (preko 100 000) su zamijenjene nedostajućim vrijednostima, a potom su nedostajuće vrijednosti zamijenjene medijanom te kolone. Nakon čišćenja vrijednosti se nalaze u rasponu od 10 do 34 516, medijana iznosi 3 473 dok je srednja vrijednost 6 587, što ukazuje na desno asimetričnu distribuciju.



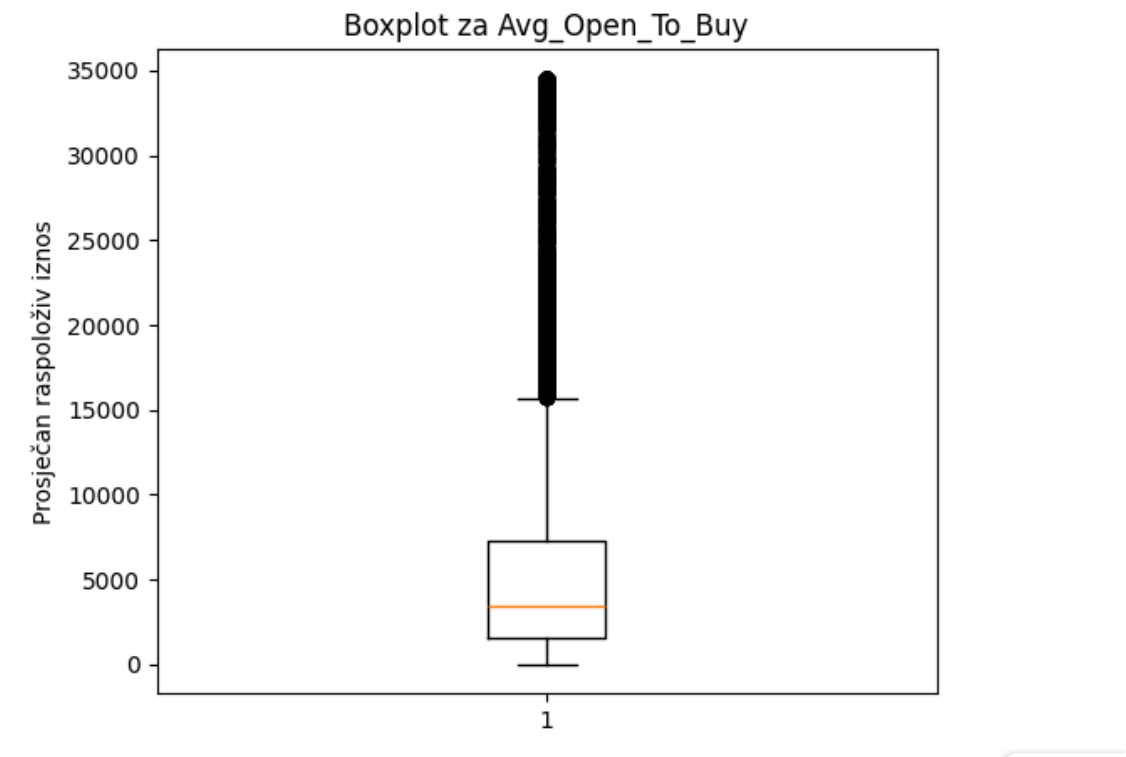
Slika 50: Prikaz distribucije za Avg_Open_To_Buy

Na *slici 50* vidim oda ima ukupno 10 127 zapisa. Srednja vrijednost iznosi približno 6 588, dok je medijana znatno niža (3 473), što ukazuje na izraženu desnu asimetriju distribucije. Ova razlika između srednje vrijednosti i medijane znači da manji broj korisnika ima vrlo visoke raspoložive iznose, koji povlače prosjek naviše. Interkvartilni raspon pokazuje da se 50% korisnika nalazi između 1 601 i 7 254, što ukazuje na veliku varijabilnost raspoloživog kreditnog prostora među klijentima. Minimalna vrijednost iznosi 10, dok maksimalna vrijednost dostiže 34 516, što dodatno potvrđuje prisustvo ekstremnih vrijednosti. Standardna devijacija je visoka (8 205), što ukazuje na značajnu raspršenost podataka.



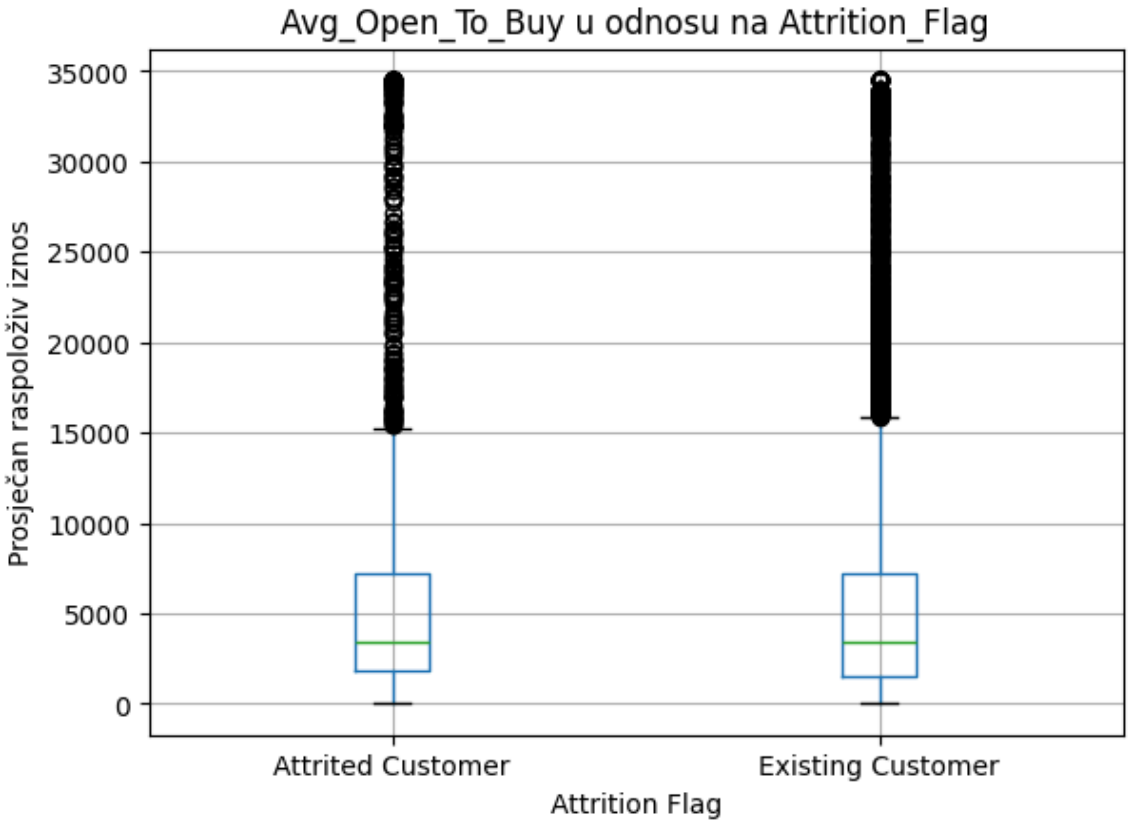
Slika 51: Histogram raspodjele prosječnog raspoloživog kreditnog iznosa po korisniku

Na *slici 51* uočava se da je najveća koncentracija vrijednosti u nižem rasponu, približno između 0 i 5 000, što znači da većina korisnika ima relativno ograničen raspoloživ kreditni prostor. Distribucija je izraženo desno asimetrična, sa dugim repom koji se proteže ka visokim vrijednostima (do oko 35 000). Ovakav oblik distribucije ukazuje da manji broj korisnika ima vrlo visoke raspoložive iznose, dok većina klijenata koristi znatno manji kreditni kapacitet. Prisustvo visokih vrijednosti potvrđuje rezultate iz deskriptivne statistike, gdje je srednja vrijednost znatno veća od medijane. Ovakva raspodjela sugeriše da analizirana varijabla sadrži značajnu informaciju o finansijskoj snazi korisnika, ali i da je osjetljiva na ekstremne vrijednosti.



Slika 52: Boxplot za Avg_Open_To_Buy

Na *slici 52* boxplotom je prikazana raspodjela prosječnog raspoloživog kreditnog iznosa kod korisnika. Medijana se nalazi oko vrijednosti 3 500, a interkvartilni raspon je relativno širok i obuhvata približno interval od 1 600 do 7 250, što ukazuje na značajnu varijabilnost među korisnicima. Veliki broj outliera na višem kraju raspodjele ukazuje na snažnu desnu asimetriju, što je u skladu s histogramom i deskriptivnom statistikom.



Slika 53: Prikazani odnos između varijabli Avg_Open_to_Buy u odnosu na ciljnu varijablu

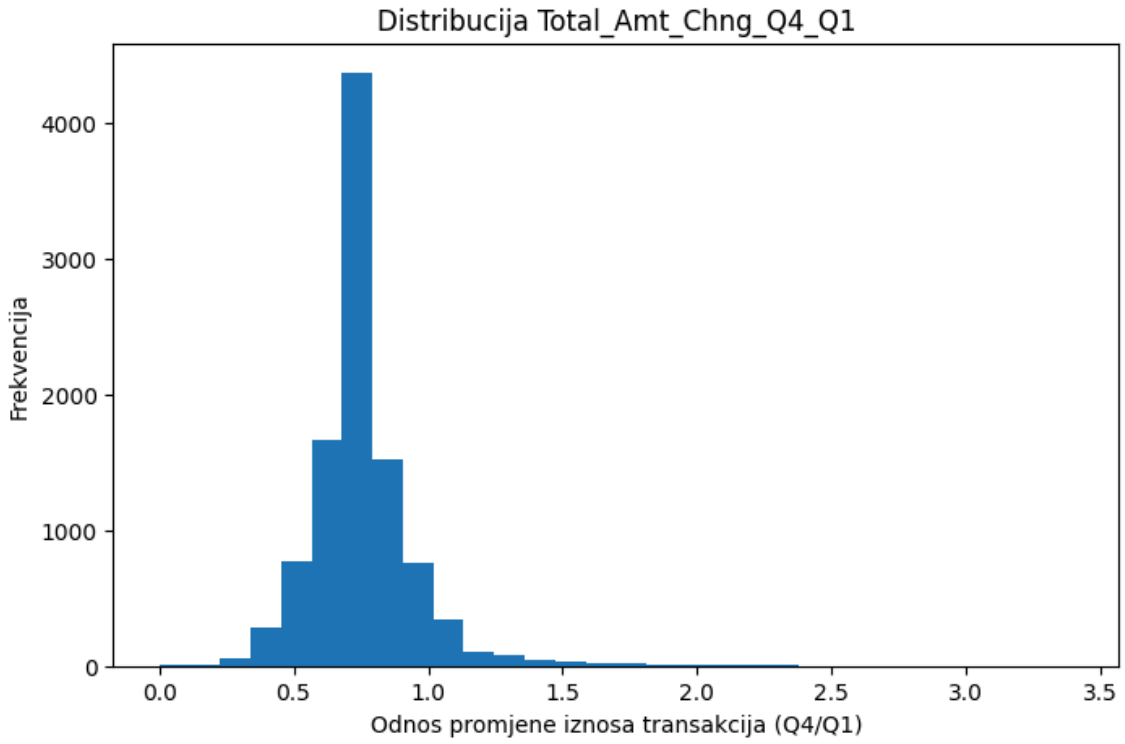
Na *slici 53* boxplot uspoređuje raspodjelu prosječnog raspoloživog kreditnog iznosa između odlazećih i postojećih korisnika. Obje grupe imaju sličan opseg vrijednosti i izraženu desnu asimetriju, sa velikim brojem ekstremnih vrijednosti na višem kraju raspodjele. Postojeći korisnici imaju blago višu medijanu raspoloživog iznosa u poređenju s odlazećim korisnicima. To ukazuje da klijenti koji ostaju u banci u prosjeku raspolažu većim neiskorištenim kreditnim kapacitetom, dok odlazeći korisnici češće imaju niže vrijednosti *Avg_Open_To_Buy*. Prisustvo velikog broja outliera u obje grupe ukazuje na heterogenost klijenata.

Kolona **Total_Amt_Chng_Q4_Q1** predstavlja relativnu promjenu transakcija između 4. I 5. kvartala. Analizom prvobitnih podataka utvrđeno je da kolona sadrži specifične simbole, esktremne numeričke vrijednosti kao i nedostajuće vrijednosti. Tokom čišćenja su uklonjeni svi nenumerički karakteri, a podaci su konvertovani u numerički format. Negativne i ekstremne vrijednosti su zamijenjene nedostajućim vrijednostima, a potom su one zamijenjene medianom kolone. Nakon čišćenja, kolona pokazuje stabilnu distribuciju. Srednja vrijednost i medijana su veoma bliske što ukazuje da distribucija nije značajno asimetrična i da nema izraženog uticaja ekstremnih vrijednosti. Sve vrijednosti su između 0.0 i 3.397

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean         0.755020
std          0.196356
min          0.000000
25%          0.665000
50%          0.737000
75%          0.819000
max          3.397000
Name: Total_Amt_Chng_clean, dtype: float64
```

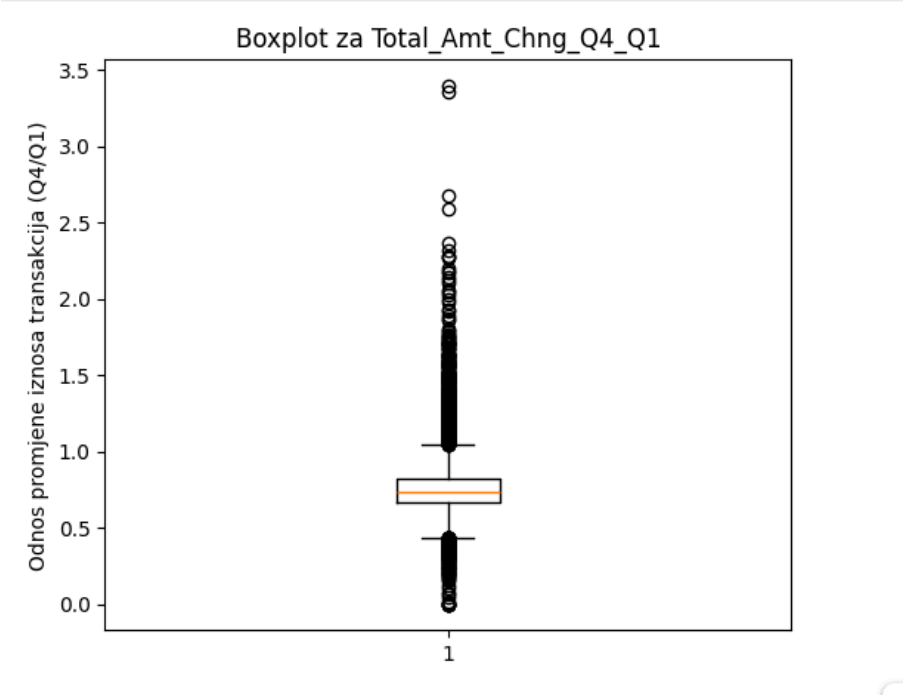
Slika 54: Prikaz distribucije za Total_Amt_Chng_Q4_Q1

Na slici 54 se može primjetiti ukupno 10 127 zapisa. Srednja vrijednost je približno 0.76, a medijana je oko 0.74: Ovo ukazuje da većina korisnika bilježi blagi pad ukupnog iznosa transakcija u Q4 u odnosu na Q1. Interkvartilni raspon pokazuje da se 50% korisnika nalazi između 0.665 i 0.819, što ukazuje na relativno stabilno ponašanje većine klijenata bez ekstremnih promjena u potrošnji. Minimalna vrijednost iznosi 0, što ukazuje na slučajeve potpunog izostanka transakcija u jednom od kvartala, dok maksimalna vrijednost dostiže 3 397, što predstavlja značajan porast potrošnje kod manjeg broja korisnika. Ekstremne promjene su rijetke što nam govori relativno niska standardna devijacija (0.196).



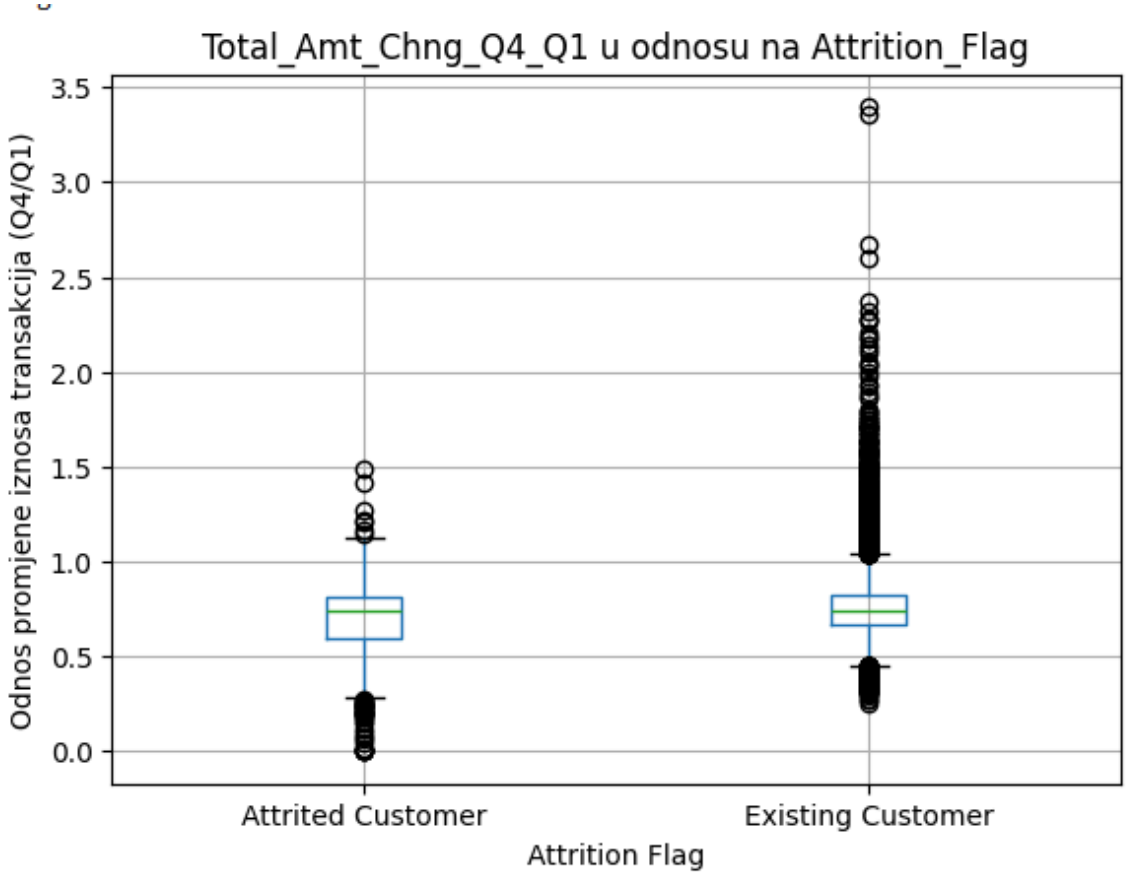
Slika 55: Histogram raspodjele odnosa promjene ukupnog iznosa transakcija između 4. I 1. Kvartala

Na *slici 55* može se primijetiti da je distribucija desno asimetrična, sa dugim repom prema većim vrijednostima, što ukazuje da manji broj korisnika ostvaruje značajan porast potrošnje (vrijednosti veće od 1.5). Takvi slučajevi su rijetki u poređenju s glavnom masom podataka. Promjena potrošnje kod većine klijenata je umjerena.



Slika 56: Boxplot za Total_AMt_Chng_Q4_Q1

Na *slici 56* boxplot prikazuje raspodjelu odnosa promjene ukupnog iznosa transakcije između 4. i 1. Kvartala. Medijana se nalazi približno na vrijednosti oko 0.7 pa polovina korisnika bilježi pad iznosa transakcija u Q4 u odnosu na Q1. Interkvartilni raspon je uzak na intervalu između 0.6 i 0.8 što nam ukazuje na stabilno ponašanje većine klijenata bez velikih oscilacija u potrošnji. Outlieri se protežu do vrijednosti 3, što predstavlja slučajeve naglog porasta potrošnje kod manjeg broja korisnika.



Slika 57: Odnos između Total_Amt_Chng_Q4_Q1 i ciljne varijable

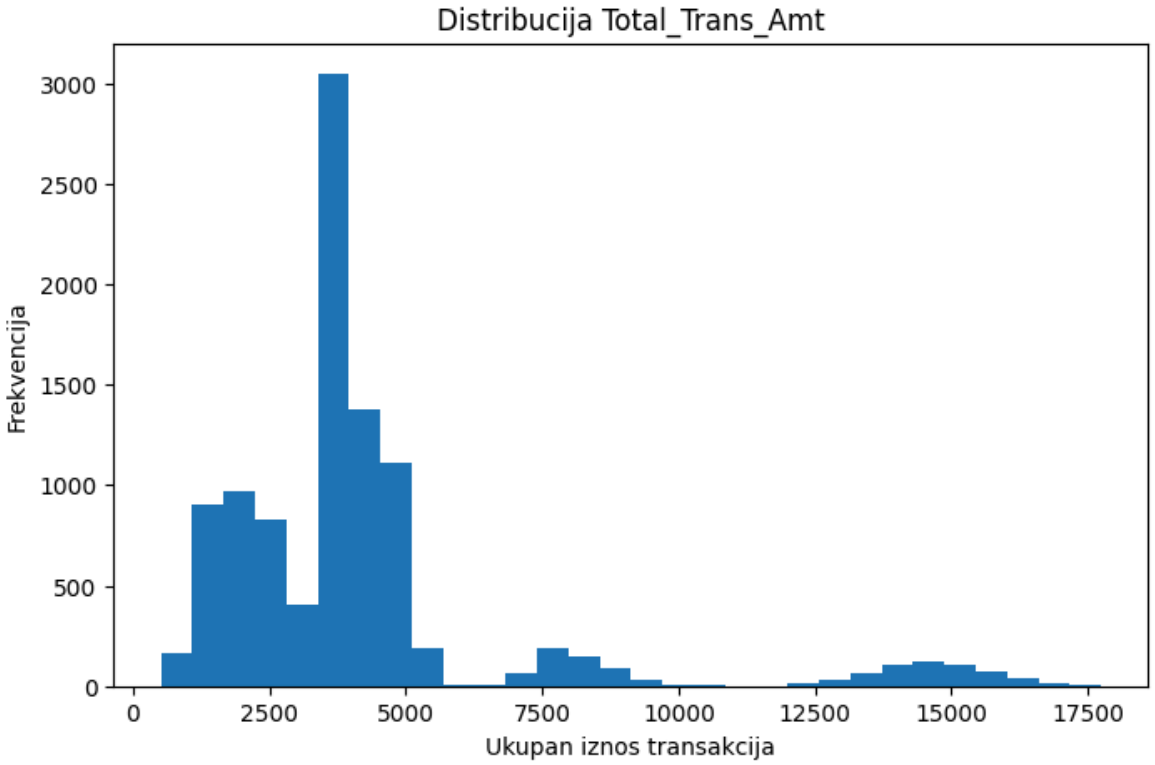
Na *slici 57* boxplot uspoređuje raspodjelu odnosa promjene ukupnog iznosa transakcija između četvrtog i prvog kvartala kod odlazećih (Attrited Customer) i postojećih korisnika (Existing Customer). Uočava se da postojeći korisnici imaju blago višu medijanu vrijednosti, što ukazuje da oni u prosjeku bilježe manji pad ili čak porast iznosa transakcija u Q4 u odnosu na Q1. Medijana je niža kod odlazećih korisnika je i raspodjela je više koncentrisana ispod vrijednosti 1, što znači da većina ovih klijenata ima izraženiji pad potrošnje. Interkvartilni raspon kod postojeće grupe je nešto širi i pomjeren ka višim vrijednostima, dok je kod odlazećih korisnika pomjeren ka nižim vrijednostima. Kod postojećih korisnika prisutan je veći broj outliera sa visokim vrijednostima, što je rijetkost kod odlazećih korisnika što nam sugeriše da je pad iznosa transakcija snažno povezan s većom vjerovatnoćom odliva klijenata.

Kolona Total_Trans_Amt predstavlja vrijednosti ukupnih transkacija i analizom ove kolone utvrđene su promjene poput dodavanaj specifičnih simbola, negativne vrijednosti i ekstremne vrijednosti. Nakon uklanjanja svih nenumeričkih znakova, vrijednosti su konvertovane u numerički format. Negativne i ekstremne vrijednosti su zamijenjene medianom kolone. Nakon čišćenja, distribucija ukupnog iznosa transakcija pokazuje desnu asimteriju, što je i očekivano za finansijske podatke. Medijana iznosi oko 3 900, dok većina klijenata ostvaruje ukupni promet između 2 500 i 4 500.

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean      4294.708206
std       2985.454173
min        510.000000
25%       2530.000000
50%       3899.000000
75%       4503.000000
max      17744.000000
Name: Total_Trans_Amt_clean, dtype: float64
```

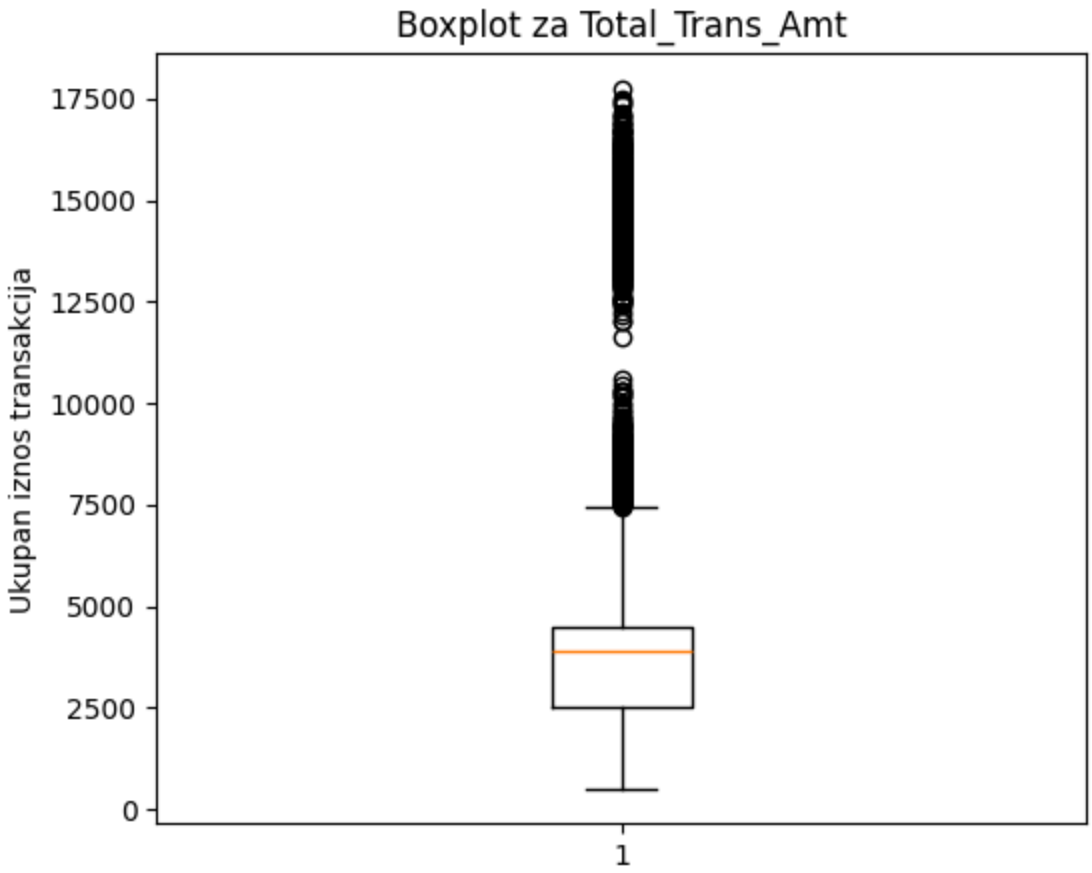
Slika 58: Prikaz distribucije za Total_Trans_Amt

Na *slici 58* prikazan je rezultat za analiziranu kolonu nakon čišćenja. Ukupan broj vrijednosti je 10 127. Srednja vrijednost ukupnog iznosa transakcija iznosi približno 4 295, dok je medijana nešto niža (3 899), što ukazuje na desnu asimetriju distribucije. Ova razlika sugeriše da manji broj korisnika sa vrlo visokim iznosima transakcija povlači prosjek naviše. Interkvartilni raspon pokazuje da se 50% korisnika nalazi između 2 530 i 4 503, što ukazuje na relativno stabilnu potrošnju kod većine klijenata. Minimalna vrijednost iznosi 510, dok maksimalna dostiže 17 744, što potvrđuje postojanje korisnika sa znatno većim obimom transakcija. Raspršenost podataka je umjerne obzirom da je standardna devijacija 2 985.



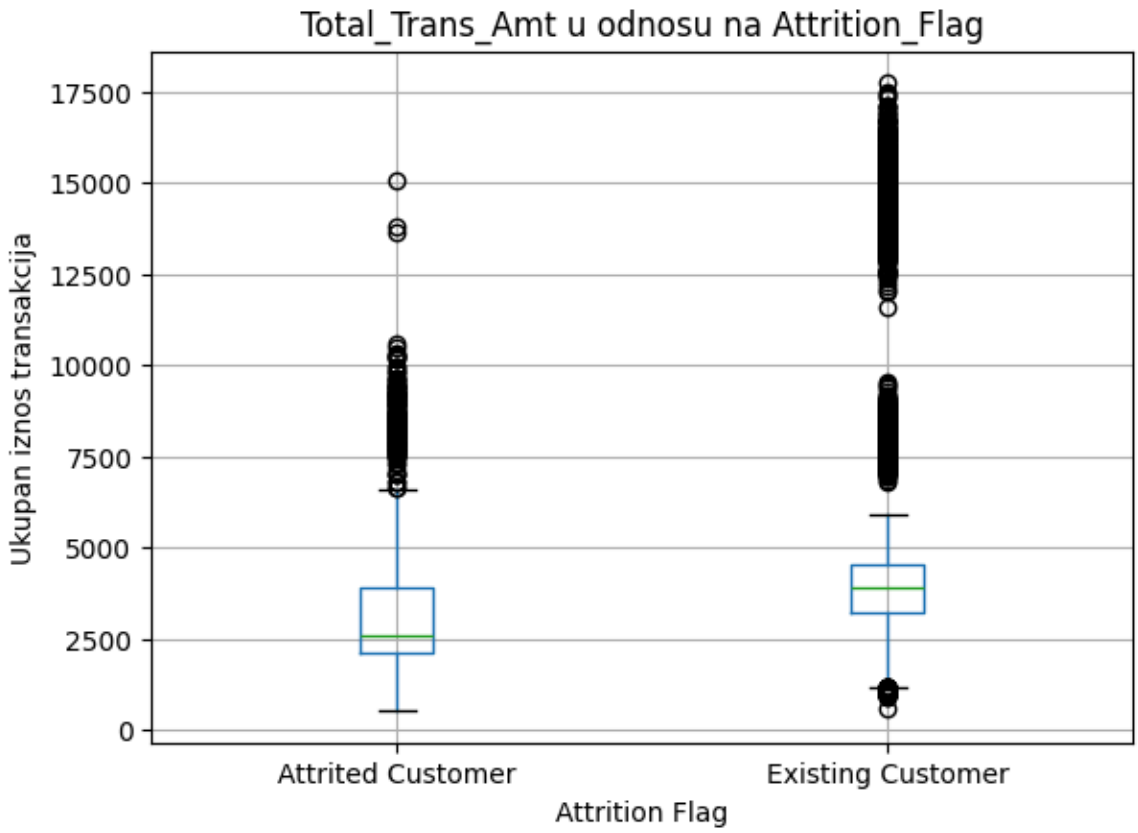
Slika 59: Histogram raspodjele ukupnog iznosa transakcija po korisniku

Na *slici 59* histogram prikazuje raspodjelu ukupnog iznosa transakcija po korisniku. Uočava se da je najveći broj korisnika koncentrisan u nižem i srednjem rasponu ukupne potrošnje, dok se frekvencija smanjuje sa porastom iznosa transakcija. Distribucija je desno asimetrična. Prisustvo dugog desnog repa sugeriše postojanje intenzivnih korisnika bankarskih usluga, dok većina klijenata ostvaruje umjerenu ukupnu potrošnju.



Slika 60: Boxplot za Total_Trans_Amt

Na *slici 60* boxplot prikazuje raspodjelu ukupnog iznosa transakcija po korisniku i omogućava uvid u centralne vrijednosti, raspon i prisustvo ekstremnih vrijednosti. Medijana ukupnog iznosa transakcija nalazi se oko 3 900, što znači da polovina korisnika ostvaruje manji, a polovina veći iznos transakcija od ove vrijednosti. Interkvartilni raspon obuhvata približno interval od 2 530 do 4 503, što ukazuje da se većina korisnika nalazi u umjerenom rasponu potrošnje. Iznad vrijednosti od 7 500 uočen je veći broj outliera, koji se protežu sve do oko 17 700, što predstavlja korisnike sa izuzetno visokim ukupnim iznosima transakcija. Ovakav obrazac ukazuje na značajne razlike u intenzitetu korištenja bankarskih usluga među klijentima.



Slika 61: Odnos između Total_Trans_Amt i ciljne varijable

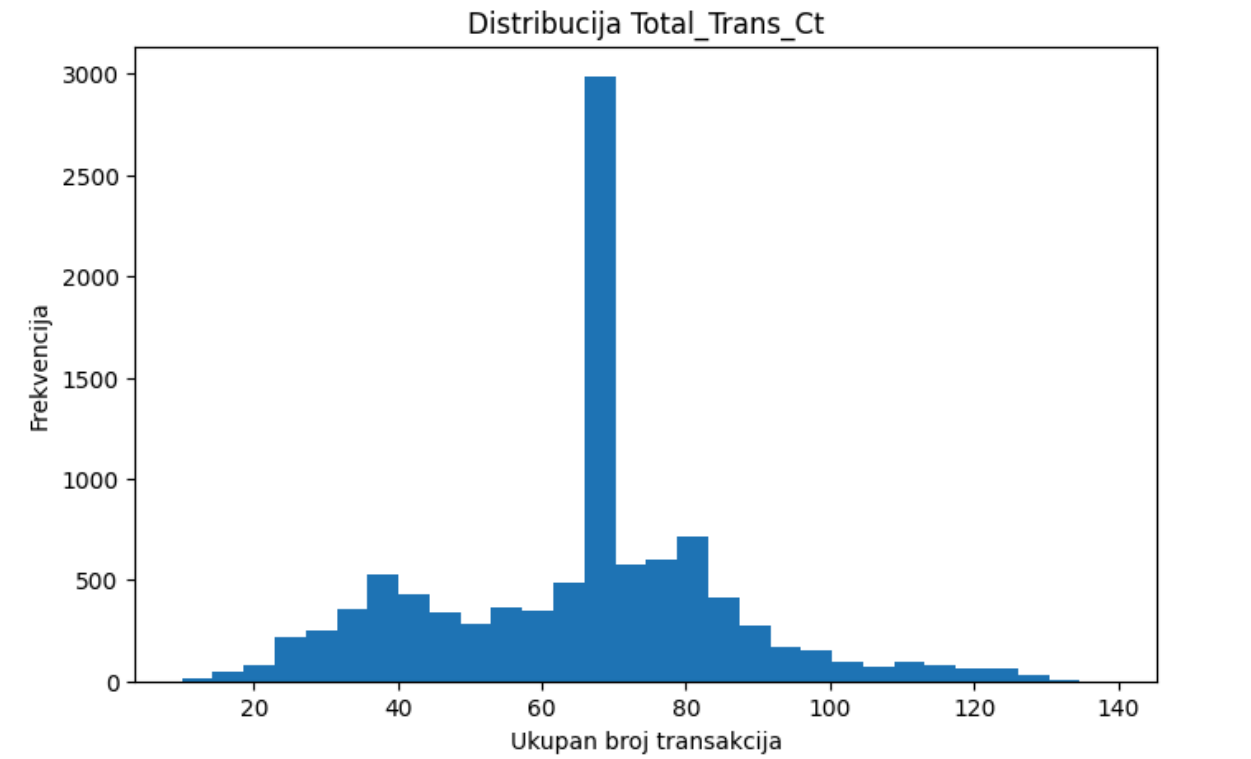
Na *slici 61* Uočava se da postojeći korisnici imaju znatno višu medijanu ukupnog iznosa transakcija, što ukazuje da u prosjeku ostvaruju veći obim potrošnje u poređenju s klijentima koji napuštaju banku. Interkvartilni raspon kod postojećih korisnika je pomjeren ka višim vrijednostima, dok je kod odlazećih korisnika koncentrisan u nižem rasponu iznosa. Ovo znači da klijenti koji odlaze generalno manje koriste bankarske usluge i imaju niži intenzitet transakcija. Također, kod postojećih korisnika prisutan je veći broj outliera sa veoma visokim iznosima transakcija, što potvrđuje postojanje grupe izrazito aktivnih klijenata. Iako u obje grupe postoje ekstremne vrijednosti, razlika u centralnim mjerama jasno ukazuje da je niži ukupni iznos transakcija povezan s većom vjerovatnoćom odliva klijenata.

Kolona Total_Trans_Ct predstavlja ukupan broj svih transakcija u posmatranom periodu. U ovoj koloni su prijećene vrijednosti koje su bile sa dodatim specifičnim simbolima, zatim negativne vrijednosti i ekstremne vrijednosti, što nike karakteristično za ovaj tip varijable. Nakon uklanjanja nenumeričkih znakova i konverzije u numerički format, sve negativne i ekstremne vrijednosti su zamijenjene medianom te kolone. Postavljena je gornja granica od 2000 transakcija. Rezultat čišćenja pokazuje stabilnu distribuciju broja transakcija klijenata. Medijana je vrlo bliska prosjeku, što pokazuje da distribucija nije značajno asimetrična i da ekstremne vrijednosti ne dominiraju skupom podataka. Sve vrijednosti su između 10 i 139.

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean        65.292387
std         20.641201
min         10.000000
25%         52.000000
50%         67.000000
75%         76.000000
max        139.000000
Name: Total_Trans_Ct_clean, dtype: float64
```

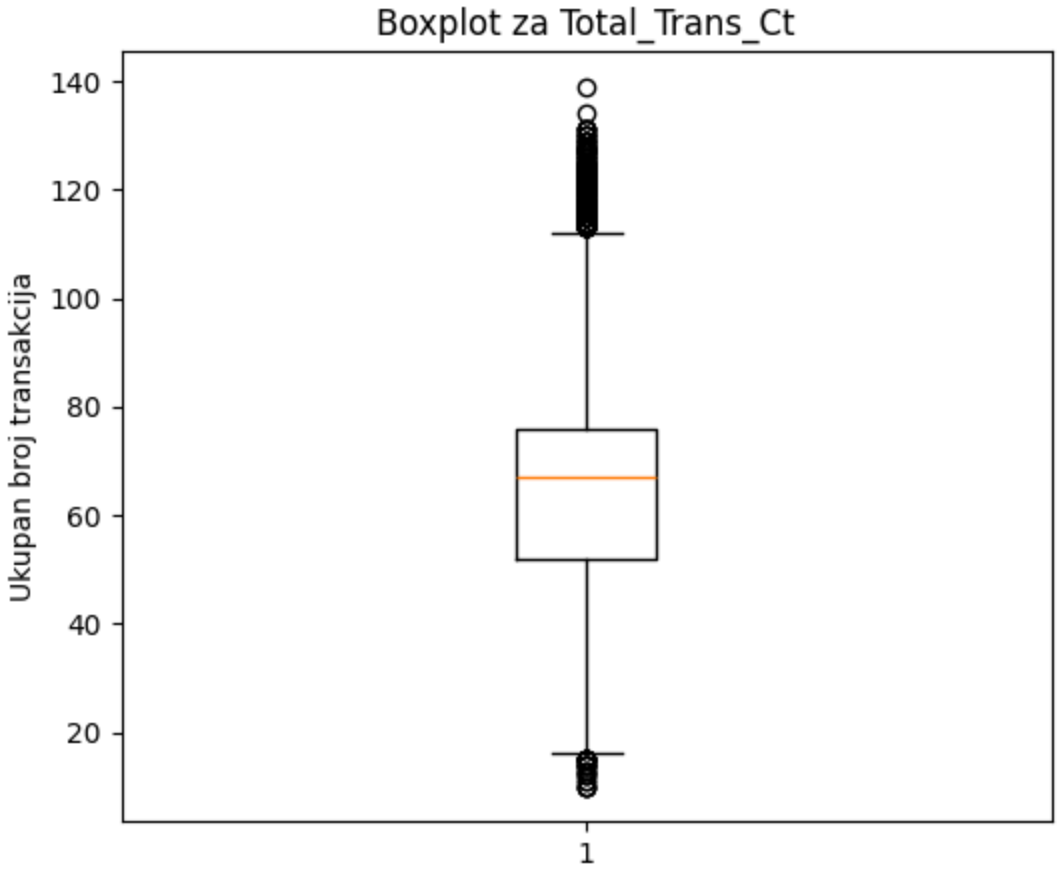
Slika 62: Prikaz distribucije za Total_Trans_Ct

Na *slici 62* vidimo ukupno 10 127 zapisa da su analizirani . Prosječan broj transakcija iznosi približno 65, dok je medijana nešto viša (67), što ukazuje na blagu asimetriju distribucije. Interkvartilni raspon pokazuje da se 50% korisnika nalazi između 52 i 76 transakcija, što sugeriše relativno stabilno i ujednačeno ponašanje većine klijenata u pogledu učestalosti korištenja bankarskih usluga. Minimalna vrijednost iznosi 10, dok maksimalna dostiže 139 transakcija, što ukazuje na postojanje korisnika sa izrazito visokim intenzitetom aktivnosti. Standardna devijacija od 20.64 pokazuje umjerenu raspršenost podataka i značajne razlike među korisnicima po broju transakcija.



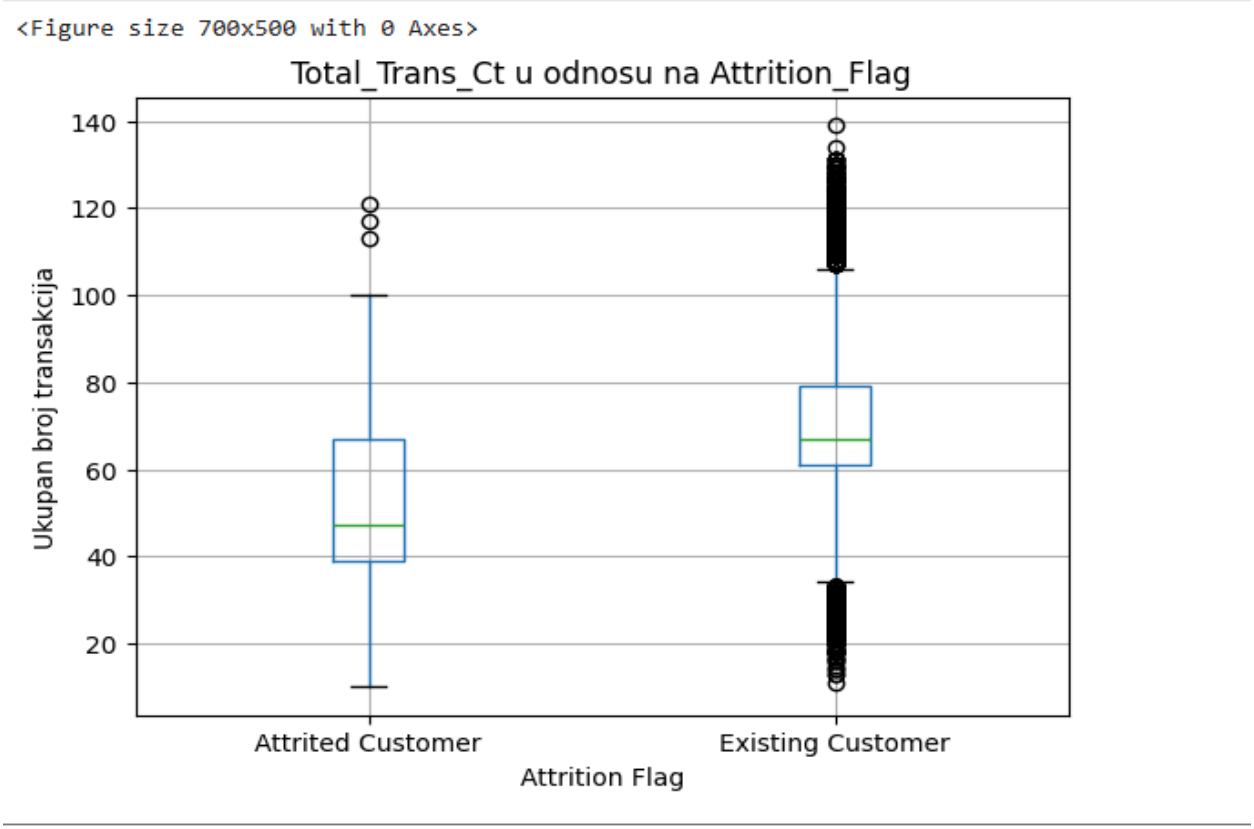
Slika 63: Histogram raspodjele ukupnog broja transakcijakoje su korisnici ostvarili u posmatranom periodu

Na slici 63 Uočava se da je najveća koncentracija vrijednosti između približno 50 i 80 transakcija, sa izraženim vrhom oko 60–70, što potvrđuje nalaze deskriptivne statistike gdje se medijana nalazi na vrijednosti 67. Distribucija je blago desno asimetrična, sa manjim brojem korisnika koji ostvaruju veoma visok broj transakcija (iznad 100), što formira produženi desni rep distribucije. Ovi korisnici predstavljaju izrazito aktivne klijente banke, ali čine relativno mali dio ukupnog uzorka. S druge strane, manji broj korisnika ima nizak broj transakcija pa tomože ukazivati na slabiju aktivnost i potencijalno veći rizik od odliva.



Slika 64: Boxplot za Total_Trans_Ct

Na *slici 64* boxplot prikazuje raspodjelu ukupnog broja transakcija po korisniku. Medijana broja transakcija iznosi približno 67, što znači da polovina korisnika ostvaruje manji, a polovina veći broj transakcija od ove vrijednosti. Interkvartilni raspon se nalazi otprilike između 52 i 76, što ukazuje da većina korisnika ima umjeren i stabilan nivo aktivnosti. Donja granica raspodjele nalazi se oko 10–15 transakcija, što predstavlja najmanje aktivne korisnike, dok se gornja granica osnovne raspodjele proteže do oko 110 transakcija. Iznad ove vrijednosti uočen je veći broj outliera, koji dostižu i do 140 transakcija, što ukazuje na postojanje izrazito aktivnih korisnika. Prisustvo outliera na gornjem kraju i blaga desna asimetrija raspodjele u skladu su s histogramom i deskriptivnom statistikom.



Slika 65: Odnos između Total_Trans_Ct i ciljne varijable

Na slici 65 Kod postojećih korisnika medijana ukupnog broja transakcija nalazi se oko 65–70, dok je kod odlazećih korisnika znatno niža, oko 45–50. Ova razlika jasno ukazuje da klijenti koji ostaju u banci ostvaruju veći broj transakcija i intenzivnije koriste bankarske usluge. Interkvartilni raspon kod postojećih korisnika je pomjeren ka višim vrijednostima, dok je kod odlazećih korisnika koncentrisan u nižem rasponu broja transakcija. Također, kod postojećih korisnika prisutan je veći broj outliera sa veoma visokim brojem transakcija (preko 100), što potvrđuje postojanje grupe izrazito aktivnih klijenata. Kod odlazećih korisnika takvi ekstremni slučajevi su rjeđi. Niži ukupan broj transakcija je snažno povezan s većom vjerovatnoćom odliva klijenata.

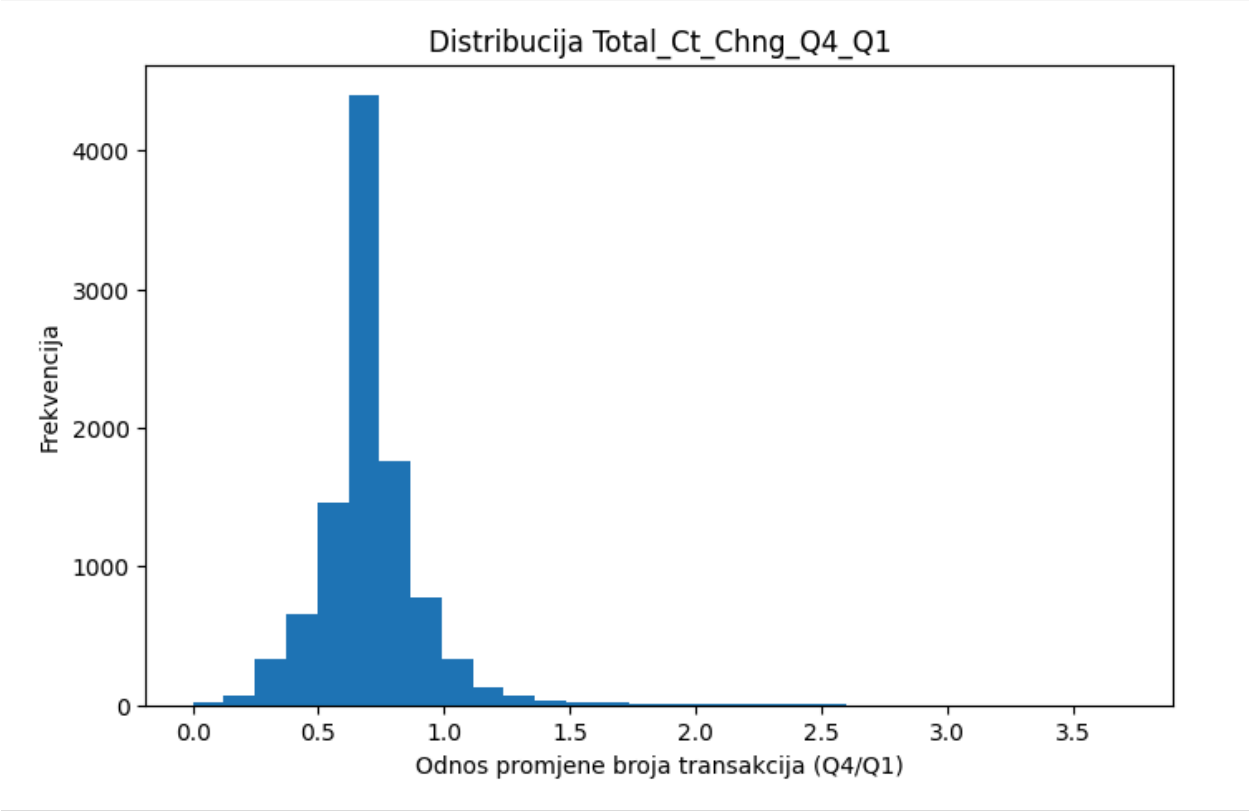
Kolona **Total_Ct_Chng_Q4_Q1** predstavlja omjer transkacija klijenta u četvrtom kvartalu u odnosu na prvi kvartal. Analizom ove kolone utvrđene su nepravilnosti poput specifičnih simbola, negativnih vrijednosti i ekstremnih vrijednosti. Podaci su očišćeni uklanjanjem nenumeričkih znakova, konverzijom u numerički format i filtriranjem vrijednosti van opsega. Negativne vrijednosti su uklonjene, jer omjer ne može biti manji od 0, dok su ekstremno visoke vrijednosti veće od 10 smtrane nerealnim, pa su ovakve vrijednosti označene kao nedostajuće i zamijenjne su medianom kolone, čime je očuvana distribucija podataka. Što se tiče rezultata nakon čišćenja vrijednost medijane je bliska srednjoj vrijednosti, a sve vrijednosti se nalaze između 0.0 i 3.714.

```
Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean         0.709383
std          0.215126
min          0.000000
25%          0.618000
50%          0.700000
75%          0.780000
max          3.714000
Name: Total_Ct_Chng_clean, dtype: float64
```

Slika 66: Prikaz distribucije za Total_Ct_Chng_Q4_Q1

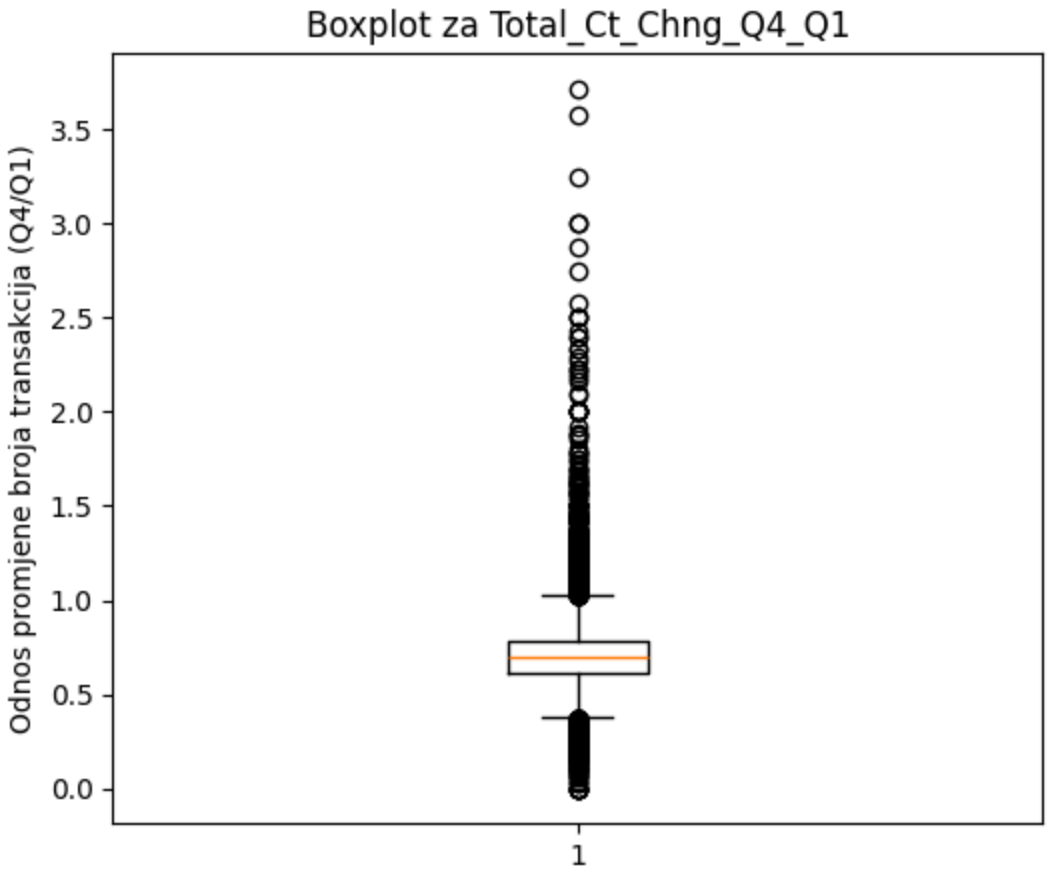
Na *slici 66* vidimo da je srednja vrijednost 0.71, dok je medijana 0.70, što pokazuje da je distribucija relativno simetrična i da većina korisnika bilježi blagi pad ili stagnaciju broja transakcija u Q4 u odnosu na Q1. Vrijednosti odnosa manje od 1 ukazuju na smanjenje broja transakcija, dok vrijednosti veće od 1 označavaju porast aktivnosti. Standardna devijacija od 0.22 sugerira umjerenu varijabilnost podataka, odnosno da se većina korisnika ne razlikuje drastično u obrascu promjene broja transakcija. Donji kvartil (25%) iznosi 0.62, a gornji kvartil (75%) 0.78, što znači da se 50% korisnika nalazi u relativno uskom intervalu promjene, blizu vrijednosti 1.

Minimalna vrijednost iznosi 0, što označava korisnike bez transakcija u jednom od kvartala, dok maksimalna vrijednost 3.71 predstavlja rijetke slučajeve značajnog rasta broja transakcija. Ove ekstremne vrijednosti su očekivane, ali čine mali dio skupa podataka.



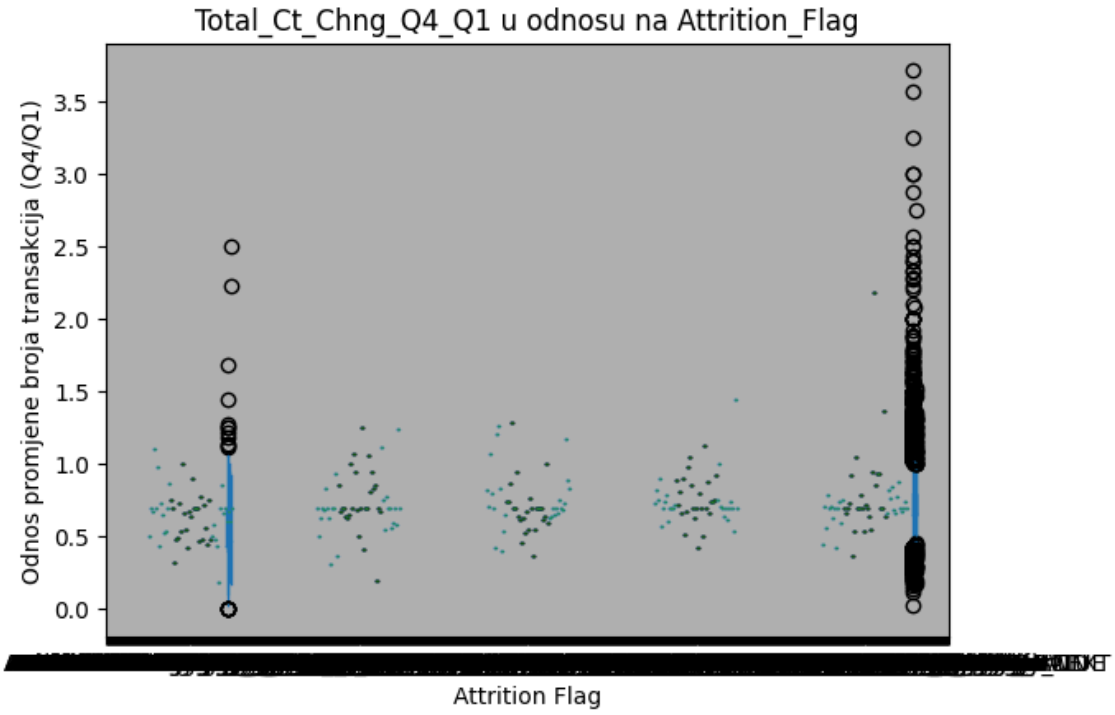
Slika 67: Histogram raspodjele odnosa promjene broja transakcija između Q4 i Q1 kvartala

Na slici 67 najveća frekvencija zabilježena je oko vrijednosti 0.7, što je u skladu sa prethodno analiziranom srednjom vrijednošću i medijanom. Distribucija je blago desno asimetrična, sa manjim brojem korisnika koji imaju vrijednosti veće od 1, što označava porast broja transakcija u Q4 u odnosu na Q1. Vrijednosti bliske nuli prisutne su u manjoj mjeri i odnose se na korisnike sa vrlo niskom ili gotovo nepostojećom aktivnošću u jednom od kvartala. Takođe, prisutan je mali broj ekstremnih vrijednosti (desni rep), ali one ne utiču značajno na ukupni oblik distribucije.



Slika 68: Boxplot za Total_Ct_Chng_Q4_Q1

Na slici 68 Interkvartilni raspon (IQR) je relativno uzak, što ukazuje na to da se većina vrijednosti nalazi u ograničenom intervalu, približno između 0.6 i 0.8. Ovo znači da je ponašanje korisnika u pogledu promjene broja transakcija relativno homogeno. Primjetan je veliki broj outliera, naročito na gornjoj strani distribucije. Ovi outlieri predstavljaju korisnike kod kojih je broj transakcija u Q4 značajno veći nego u Q1 (vrijednosti veće od 1), što su rijetki, ali izraženi slučajevi povećane aktivnosti. Sa donje strane, također, postoje izdvojene vrijednosti bliske nuli, koje ukazuju na korisnike sa izrazito malim brojem transakcija u jednom od kvartala. Distribucija je asimetrična sa izraženim desnim repom.



Slika 69: Odnos između Total_Ct_Chng_Q4_Q1 i ciljne varijable

Na *slici 69*: Kod Attrited Customer uočava se niži medijan vrijednosti Total_Ct_Chng_Q4_Q1, što ukazuje da je kod ovih klijenata došlo do izraženijeg pada broja transakcija u Q4 u odnosu na Q1. Većina vrijednosti je koncentrisana ispod ili oko 0.7, sa relativno manjim brojem ekstremnih slučajeva rasta aktivnosti. S druge strane, Existing Customer imaju viši medijan i širi raspon vrijednosti, kao i znatno veći broj outliera na gornjoj strani. To znači da među postojećim klijentima postoji veći broj onih kod kojih se broj transakcija u Q4 značajno povećao u odnosu na Q1. Rasute tačke dodatno naglašavaju razliku između dvije grupe: kod postojećih klijenata je prisutna veća varijabilnost i veća koncentracija visokih vrijednosti, dok su kod klijenata koji su napustili banku promjene uglavnom umjerene ili negativne.

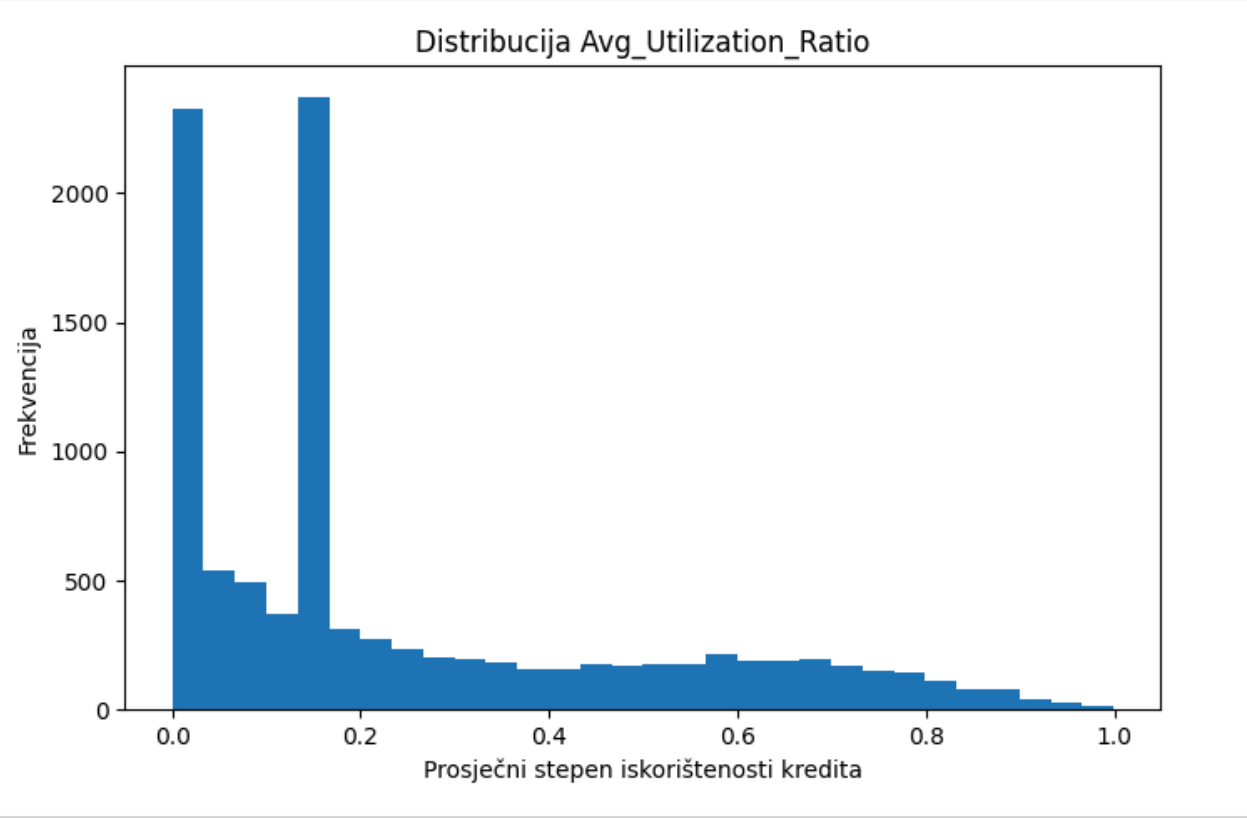
Kolona **Avg_Utilization_Ratio** predstavlja prosječan odnos iskorištenosti kreditnog limita i mora iamti vrijednosti u intervalu [0, 1]. Analizom je utvrđeno da voak olona sadrži specifilne simbole, kao i vrijednosti koje su manje od 0 i veće od 1 što nije moguće za ovu kolonu, pa predstavljaju nevalidne podatke. Tokom procesa čišćenja uklonjeni su svi nenumerički karakteri, nakon čega su vrijednosti konvertovane u numerički format. Svi nevalidni podaci su označeni kao nedostajući, a potom zamijenjene medianom ove kolone. Nakon čišćenja, većina korisnika ima nizak stepen iskorištenosti kreditnog limita, pri čemu je medijana 0.16, dok maksimalne vrijednosti ostaju unutar opsega.

```
• Deskriptivna statistika nakon čišćenja:
count    10127.000000
mean         0.245198
std          0.249181
min          0.000000
25%          0.048000
50%          0.163000
75%          0.386000
max          0.999000
Name: Avg_Utilization_Ratio_clean, dtype: float64
```

Slika 70: Prikaz distribucije za Avg_Utilization_Ratio

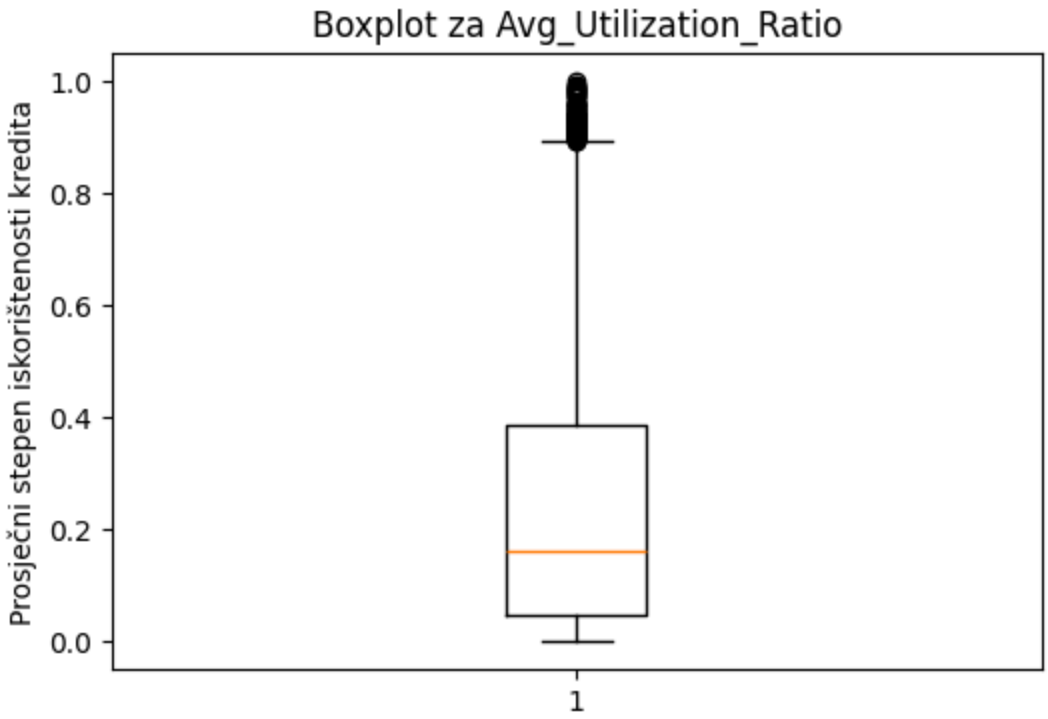
Na *slici 70* prosječna vrijednost iznosi 0.245, što ukazuje da klijenti u prosjeku koriste oko 24.5% dostupnog kreditnog limita. Medijan iznosi 0.163, što znači da polovina klijenata koristi manje od 16.3% svog limita, dok druga polovina koristi više. Standardna devijacija od 0.249 ukazuje na značajnu varijabilnost u ponašanju klijenata, odnosno razlike u stepenu iskorištenosti kreditnog limita. Prvi kvartil (Q1 = 0.048) pokazuje da 25% klijenata koristi manje od 4.8% dostupnog limita, dok treći kvartil (Q3 = 0.386) pokazuje da 75% klijenata koristi manje od 38.6% limita. Maksimalna vrijednost od 0.999 ukazuje na postojanje klijenata koji gotovo u potpunosti koriste svoj kreditni limit. Ovakva distribucija sugeriše desno asimetričnu raspodjelu,

gdje većina klijenata ima nizak stepen iskorištenosti, dok manji broj klijenata pokazuje vrlo visok nivo zaduženosti.



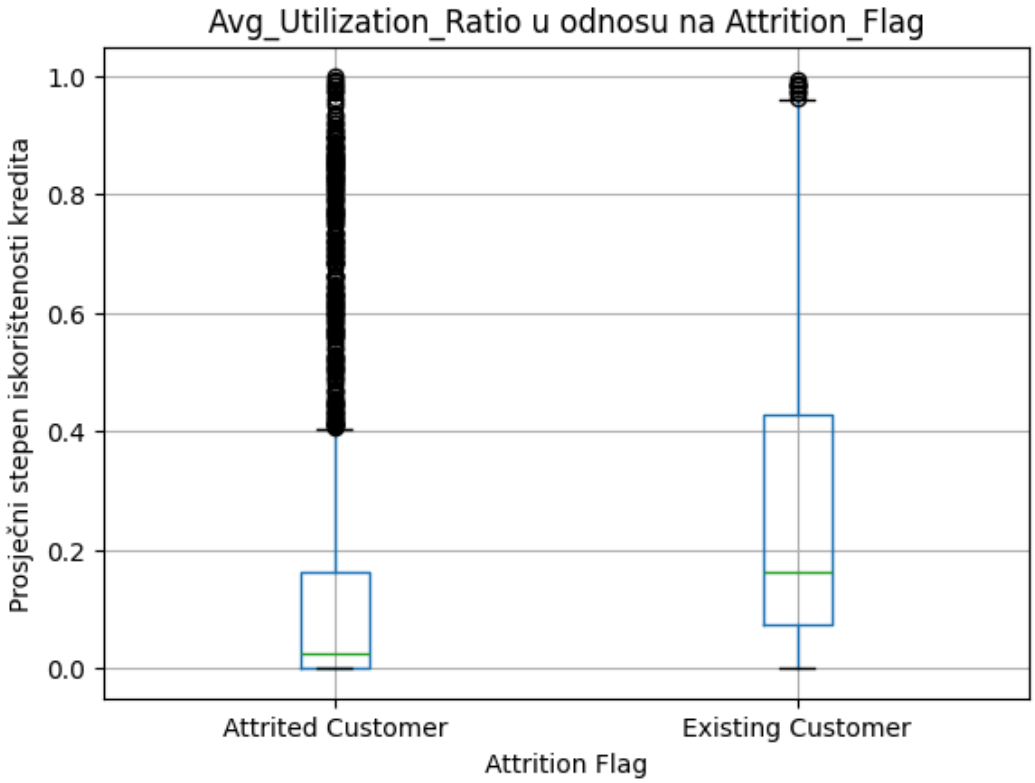
Slika 71: Histogram distribucije varijable Avg_Utilization_Ratio

Na *slici 71* histogram pokazuje da je većina vrijednosti koncentrisana u donjem dijelu opsega, posebno između 0 i 0.2, što ukazuje da veliki broj klijenata koristi relativno mali dio svog dostupnog kreditnog limita. Ovaj dio distribucije ima najveću frekvenciju, što potvrđuje prethodno uočene niske vrijednosti medijana i kvartila. Kako se vrijednost odnosa povećava, frekvencija postepeno opada, a distribucija ima dugačak desni rep, koji se proteže sve do vrijednosti blizu 1. To znači da postoji manji broj klijenata koji koriste veliki dio ili gotovo cjelokupan kreditni limit. Ovakav oblik raspodjele ukazuje na izraženu desnu asimetriju.



Slika 72: Boxplot za Avg_Utilization_Ratio

Na *slici 72* boxplot prikazuje raspodjelu prosječnog stepena iskorištenosti kreditnog limita. Medijan se nalazi na relativno niskoj vrijednosti, što potvrđuje da većina klijenata koristi mali dio svog raspoloživog kreditnog limita. Q1 je blizu nule, dok se Q3 nalazi ispod 0.4, što ukazuje da je 50% klijenata koncentrisano u donjem dijelu opsega vrijednosti. IQR je umjeren, ali je ukupna raspodjela izraženo asimetrična udesno. Prisutan je i veći broj outliera u gornjem dijelu skale, sa vrijednostima bliskim 1, što predstavlja klijente koji koriste gotovo cijeli kreditni limit.

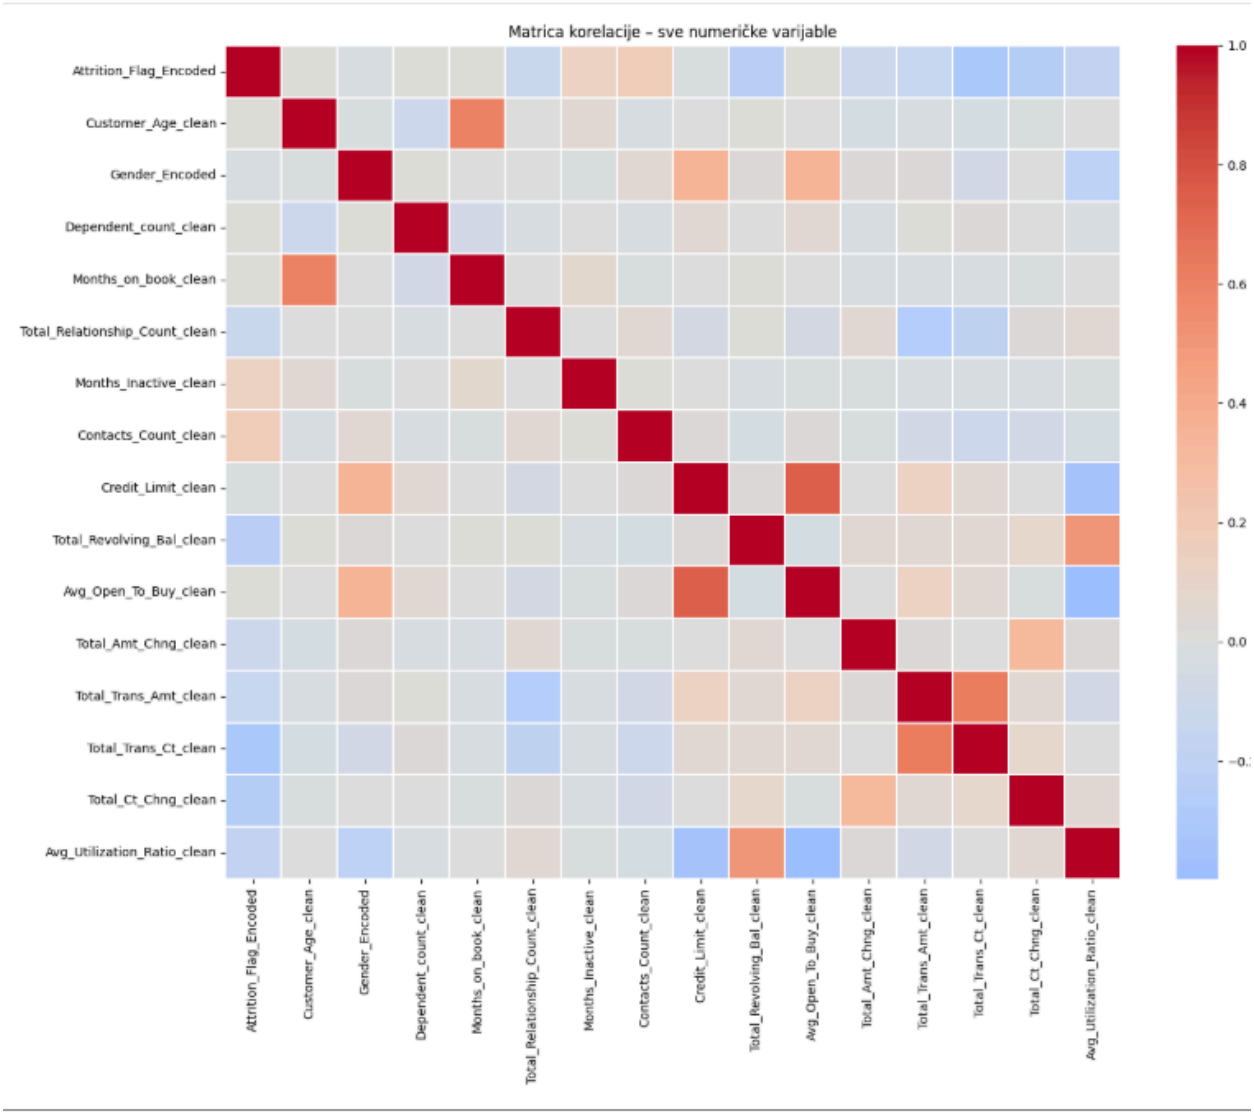


Slika 73: Odnos Avg_Utilization_Ratio sa ciljnom varijablom

Na *slici 73* Uočava se značajna razlika u centralnim vrijednostima između ove dvije grupe. Existing Customer klijenti imaju viši medijan Avg_Utilization_Ratio u odnosu na Attrited Customer klijente, što ukazuje da aktivni klijenti u prosjeku koriste veći dio svog kreditnog limita. Kod klijenata koji su napustili banku, medijan je vrlo blizu nule, što znači da većina tih klijenata koristi kreditne kartice minimalno ili gotovo nikako.IQR je znatno širi kod Existing Customer grupe, što pokazuje veću varijabilnost u ponašanju korištenja kredita među aktivnim klijentima. Suprotno tome, Attrited Customer grupa je snažno koncentrisana pri niskim vrijednostima iskorištenosti. Također, u obje grupe prisutan je veći broj outliera sa vrlo visokim vrijednostima (blizu 1), što predstavlja klijente koji koriste skoro cjelokupan kreditni limit. Međutim, ovi ekstremni slučajevi su češći i izraženiji kod Existing Customer klijenata.

Kolone koje sadrže izlaz Naive Bayes klasifikatora su uklonjene iz skupa podataka prije daljenje analize. Ove kolone ne predstavljaju izvorne karakteristike, već su rezultat predikcije modela koji je treniran ranije. Njihovo zadržavanje bi dovelo do curenja informacija i nerealno visokih performansi drugih klasifikacionih algoritama. Brisanjem ovih kolona model će se isključivo trenirati na stvarnim atributima klijenata.

Također, posljednje dvije kolone u izmijenjenom datasetu koji čistimo postoje dvije kolone Account_Status i Last_Login_Days koje nisu bile dio originalnog datasets, već su vještački dodane tokom procesa generisanja prljavog dataset-a. Zadržavanje ovih kolona bi dovelo do nekonzistentnosti između analiziranih i stvarnih podatakaa i do potencijalno pogrešnih zaključaka. Tako da su ove dvije kolone uklonjene prije dalje analize kako bi se osigurala validnost i tačnost daljeg modeliranja.



Slika 74: Matrica korelacije između numeričkih varijabli

Na *slici 74* je prikazana matrica korelacije svih numeričkih varijabli u skupu podataka. Crvene nijanse označavaju pozitivnu korelaciju, dok plave nijanse označavaju negativnu korelaciju, pri čemu su vrijednosti bliske nuli prikazane neutralnim tonovima. Uočava se da većina varijabli ima slabu međusobnu korelaciju. Ipak, prisutne su i nekoliko umjerenih do jačih korelacija koje su očekivane s obzirom na semantičko značenje varijabli.

Najizraženija pozitivna korelacija primjetna je između:

- Total_Trans_Ct_clean i Total_Trans_Amt_clean, što ukazuje da veći broj transakcija prirodno prati veći ukupni iznos transakcija.

- Credit_Limit_clean i Avg_Open_To_Buy_clean, gdje viši kreditni limit rezultira većim prosječnim raspoloživim iznosom.

- Total_Revolving_Bal_clean i Avg_Utilization_Ratio_clean, što potvrđuje da veći revolving dug dovodi do većeg stepena iskorištenosti kreditnog limita.

Kada je riječ o ciljnoj varijabli Attrition_Flag_Encoded, uočljive su negativne korelacije sa varijablama vezanim za intenzitet korištenja kartice, poput:

- Total_Trans_Ct_clean

- Total_Trans_Amt_clean

- Avg_Utilization_Ratio_clean

Ovo nam govori da klijenti koji češće koriste karticu, ostvaruju veće transakcione iznose i imaju viši stepen iskorištenosti kredita rjeđe napuštaju banku, dok su klijenti sa slabijom aktivnošću skloniji odlasku (*attrition*). S druge strane, varijable poput Customer_Age_clean, Gender_Encoded i Dependent_count_clean pokazuju vrlo slabu korelaciju sa većinom ostalih atributa, uključujući i ciljnu varijablu, što ukazuje da demografski faktori imaju manji direktni linearni uticaj u poređenju sa ponašajnim i finansijskim varijablama.